第九章 大模型用于知识图谱构建下游应用技术方案

内容提要

- 1. 知识图谱与大模型的一些认识
- 2. 大模型与知识图谱融合的几个场景
- 3. 大模型推理用于知识图谱构建的实现策略
- 4. 大模型微调用于知识图谱构建的实现策略
- 5.面向知识图谱的微调语言模型回顾

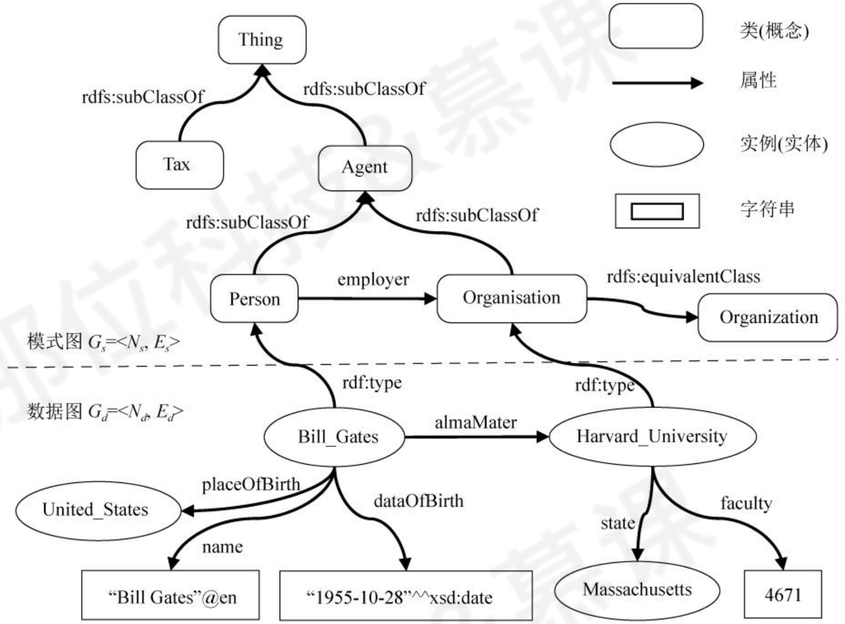
那位科技
那位科技&慕课

大模型与知识图谱的一些认识

知识图谱的概念认知

- 知识图谱：基于二元关系的知识库，用以描述现实世界中的实体或概念及其相互关系，基本组成单位是【实体−关系−实体】三元组（triplet），实体之间通过关系相互联结，构成网状结构。

- 从根本上讲，知识图谱本质上是**一种知识表示方式，其通过定义领域本体，对某一业务领域的知识结构（概念、实体属性、实体关系、事件属性、事件之间的关系）进行了精确表示**，使之成为某个特定领域的知识规范表示。随后，通过实体识别、关系抽取、事件抽取等方法从各类数据源中抽取结构化数据，进行知识填充，最终以属性图或RDF格式进行存储。



知识图谱的双层结构



知识图谱的综合理解

知识图谱研发基本流程

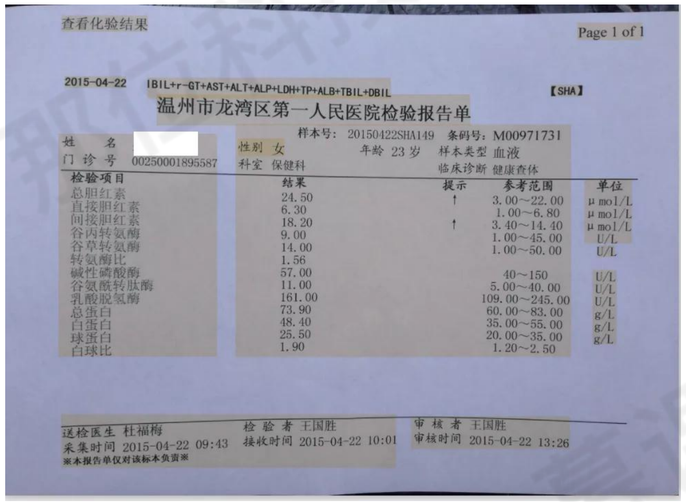


那位科技&慕课

真实场景的知识图谱落地

那位科技

拍照版医院血液检验报告单



查看化验结果 Page 1 of 1

2015-04-22 IBIL+r-GT+AST+ALT+ALP+LDH+TP+ALB+TBIL+DBIL 【SHA】

温州市龙湾区第一人民医院检验报告单

样本号：20150422SHA149 条码号：M00971731

姓 名 门诊号 00250001895587 性别 女 年龄 23岁 样本类型 血液 科室 保健科 临床诊断 健康查体

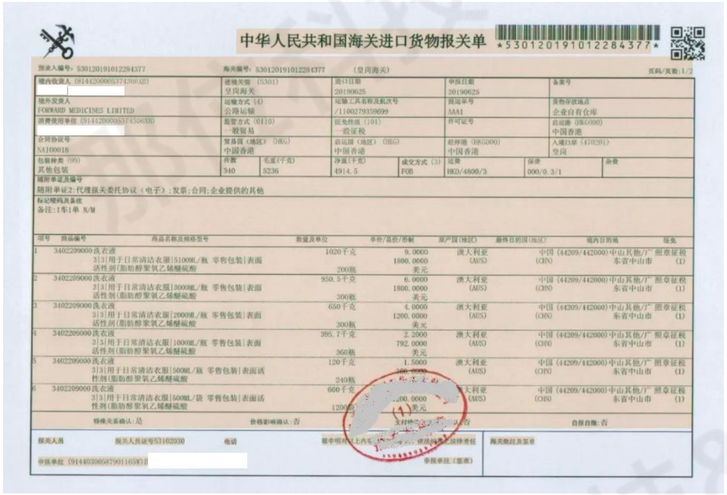
检验项目	结果	提示	参考范围	单位
总胆红素	24.50	↑	3.00~22.00	μmol/L
直接胆红素	6.30		1.00~6.80	μmol/L
间接胆红素	18.20	↑	3.40~14.40	μmol/L
谷丙转氨酶	9.00		1.00~45.00	U/L
谷草转氨酶	14.00		1.00~50.00	U/L
转氨酶比	1.56			
碱性磷酸酶	57.00		40~150	U/L
谷氨酰转肽酶	11.00		5.00~40.00	U/L
乳酸脱氢酶	161.00		109.00~245.00	U/L
总蛋白	73.90		60.00~83.00	g/L
白蛋白	48.40		35.00~55.00	g/L
球蛋白	25.50		20.00~35.00	g/L
白球比	1.90		1.20~2.50	

送检医生 杜福梅 检验者 王国胜 审核者 王国胜

采集时间 2015-04-22 09:43 接收时间 2015-04-22 10:01 审核时间 2015-04-22 13:26

※本报告单仅对该标本负责※

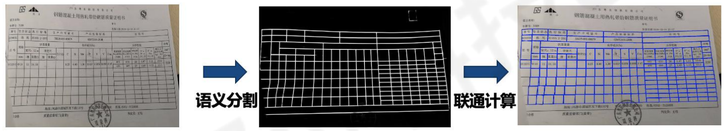
海关货品报关单/PDF表格



中华人民共和国海关进口货物报关单

垂类百科infobox

中文名	西伯利亚虎	亚　目	裂脚亚目
拉丁学名	*Panthera tigris* ssp.*altaica*	科	猫科
别　名	东北虎、阿尔泰虎、满洲虎、乌苏里虎、朝鲜虎、阿穆尔虎、俄罗斯虎	亚　科	豹亚科
		属	豹属
界	动物界	种	虎
门	脊椎动物门	亚　种	西伯利亚虎
亚　门	脊椎动物亚门	命名者及年代	Temminck, 1844 [3]
纲	哺乳纲	保护级别	濒危（EN）IUCN标准 [3]
亚　纲	真兽亚纲	同义学名	*Panthera tygris altaica*
目	食肉目	英文名称	Siberian Tiger、Amur Tiger



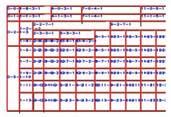
语义分割　联通计算

相机拍摄表单

牌号：HRB400E
交货状态：热轧
执行标准：GB1499.2-2007
生产许可号：XK05-001-00079
捆：12
重量：34.56

结构化数据元组

OCR文字识别　曲线拉直



输入表格

报告期内，本公司营业外收支变动情况如下：

	项目	2016年	2015年	2014年
营业外收入	金额（万元）	428.50	259.11	296.51
	占利润总额比例	3.05%	4.31%	5.82%
营业外支出	金额（万元）	209.88	290.53	462.80
	占利润总额比例	1.50%	4.83%	9.08%

表格结构化元组

（2016年，本公司，营业外收入，428.50，万元）
（2015年，本公司，营业外收入，259.11，万元）
（2014年，本公司，营业外收入，296.51，万元）
（2016年，本公司，营业外收入-占利润总额比例，3.05，%）
（2015年，本公司，营业外收入-占利润总额比例，4.31，%）
（2014年，本公司，营业外收入-占利润总额比例，5.82，%）
（2016年，本公司，营业外支出，209.88，万元）
（2015年，本公司，营业外支出，290.53，万元）
（2014年，本公司，营业外支出，462.80，万元）
（2016年，本公司，营业外支出-占利润总额比例，1.50，%）
（2015年，本公司，营业外支出-占利润总额比例，4.83，%）
（2014年，本公司，营业外支出-占利润总额比例，9.08，%）

```
</dd>
<dt class="basicInfo-item name">保护级别</dt> = $0
<dd class="basicInfo-item value">
  " 濒危（EN）"
  <a target="_blank" href="/item/IUCN">IUCN</a>
  "标准"
  <sup class="sup--normal" data-sup="3" data-ctrmap=":3,"> [3]</sup>
  <a class="sup-anchor" name="ref_[3]_16695982"> </a>
</dd>
<dt class="basicInfo-item name">同义学名</dt>   key
<dd class="basicInfo-item value">
  <i>Panthera tygris altaica</i>   value
</dd>
<dt class="basicInfo-item name">英文名称</dt>
<dd class="basicInfo-item value"> Siberian Tiger、Amur Tiger </dd>
</dl>
::after
```

真实场景的知识图谱落地

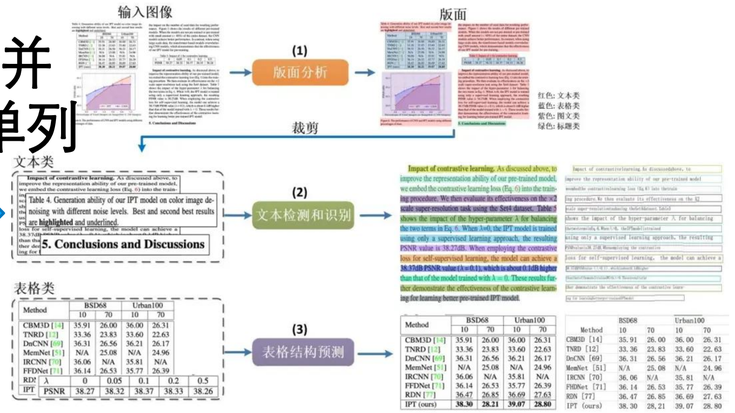
那位科技

影印PDF

版式分析



段落合并
双列转单列



实体识别/实体关系抽取/事件抽取

Docx转换

文档PDF

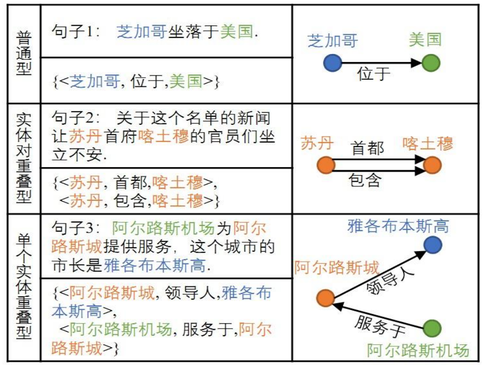


Docx文档

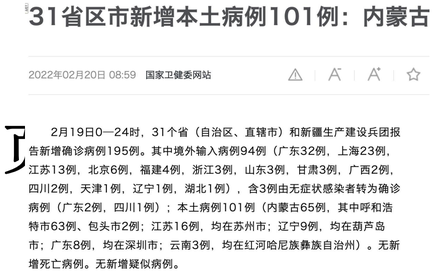
Zip转换/解压







HTML网页



参考：

HTML解析



31省区市新增本土病例101例：内蒙古65例 江苏16例
2月19日0—24时，31个省（自治区、直辖市）和新疆生产建设兵团报告新增确诊病例195例。其中境外输入病例94例（广东32例，上海23例，江苏13例，北京6例，福建4例，浙江3例，山东3例，甘肃3例，广西2例，四川2例，天津1例，辽宁1例，湖北1例），含3例由无症状感染者转为确诊病例（广东2例，四川1例）；本土病例101例（内蒙古65例，其中呼和浩特市63例、包头市2例；江苏16例，均在苏州市；辽宁9例，均在葫芦岛市；广东8例，均在深圳市；云南3例，均在红河哈尼族彝族自治州）。无新增死亡病例。无新增疑似病例。

Txt格式

知识图谱的业界认识

1、做知识图谱，本身就是在做数据，是“表面光鲜亮丽”，但背后“**脏、累、甚至“吃力不讨好”的活**

2、知识图谱是一个领域性、case by case的范畴，需要算法、产品、工程个方面的协同

3、做知识图谱的过程，就是一个**数据定义、数据挖掘、数据清洗、数据评估**的过程

4、知识图谱在业务看来，更多时候是一个领域性的大词表，一个事实性的领域强规则和知识库

5、知识图谱是一门数据科学，也是一个数据工程，非纯粹算法，**更多的是业务和工程**

6、知识图谱做好，业务指标可能不会有明显提升，但不做好，业务指标大概率不会好

7、知识图谱的价值，在于其**准确性、全面性、实时性、规范性**以及加持图结构带来的特性增益

知识图谱VS大模型

- **相同点**
  - 本质上都是一种知识库；
  - 在实时性和时效性上面临的挑战一致：
    - chatgpt遇到的事实性错误和时效性，知识
    - 而且知识图谱如果不能保证非结构化数据
    - 如果chatgpt创造出大量的内容之后，并作

	构建	推理
结构化知识	难构建，需要设计体系结构并解析	容易推理，有用的结构已经定义好了
非结构化知识	容易构建，只存储文本即可	难推理，需要抽取有用的结构
语言模型	容易构建，在非结构化文本上训练	容易推理，使用提示词即可

生

- **不同点**
  - 知识图谱是**一种知识的形式化表示**方式，**大语言模型(ChatGPT)是参数化的知识**。

  - KG优势还是在于方便debugging，人可理解，图结构表达能力强，ChatGPT就是any data，any task，无所不能，不够简单。

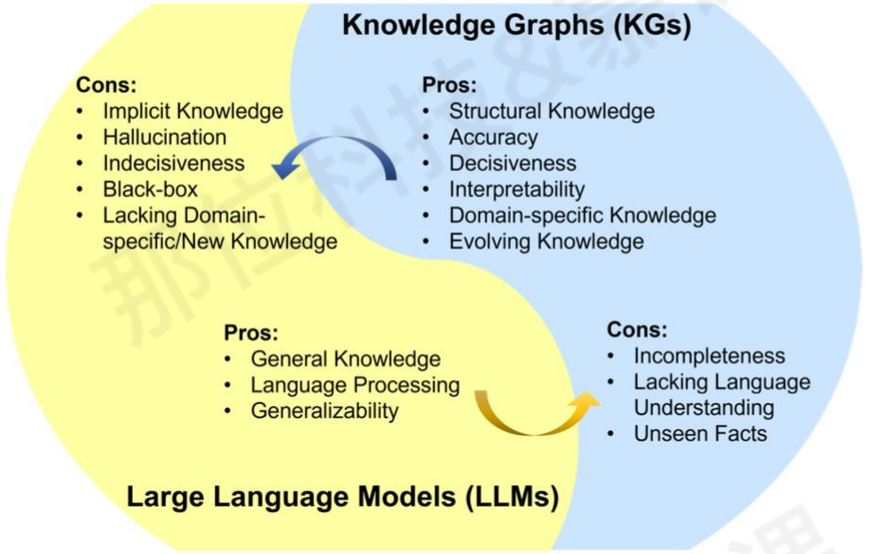
  - **结构化知识很难构建**（因为要设计知识的结构体系），**但易于推理**（因为有体系结构），**非结构化知识易于构建**（直接存起来就行），**但很难用于推理**（没有体系结构）。大语言模型提供了一种新的方法，可以轻松地从非结构化文本中提取知识，并在不需要预定义模式的情况下有效地根据知识进行推理。

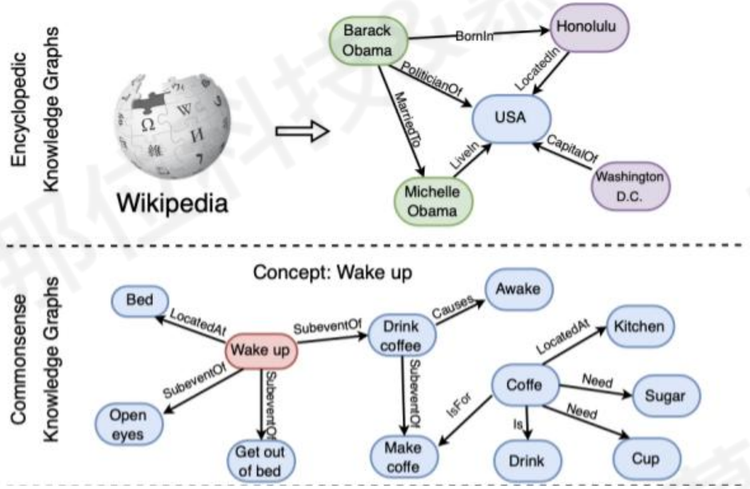
知识图谱VS大模型

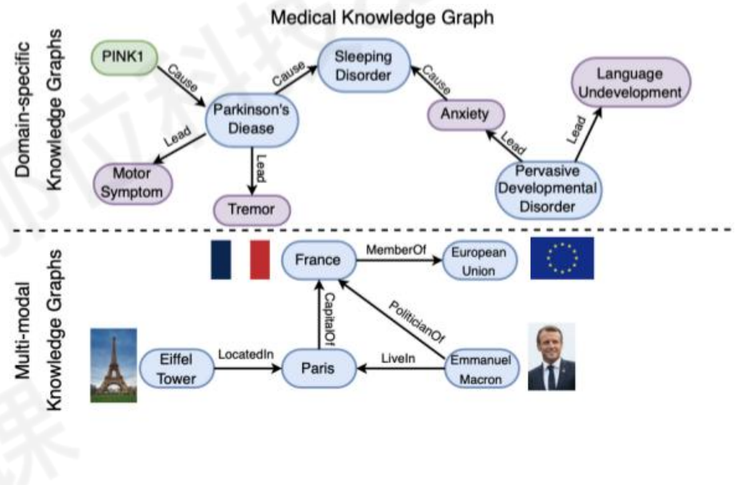
	构建	推理
结构化知识	难构建，需要设计体系结构并解析	容易推理，有用的结构已经定义好了
非结构化知识	容易构建，只存储文本即可	难推理，需要抽取有用的结构
语言模型	容易构建，在非结构化文本上训练	容易推理，使用提示词即可

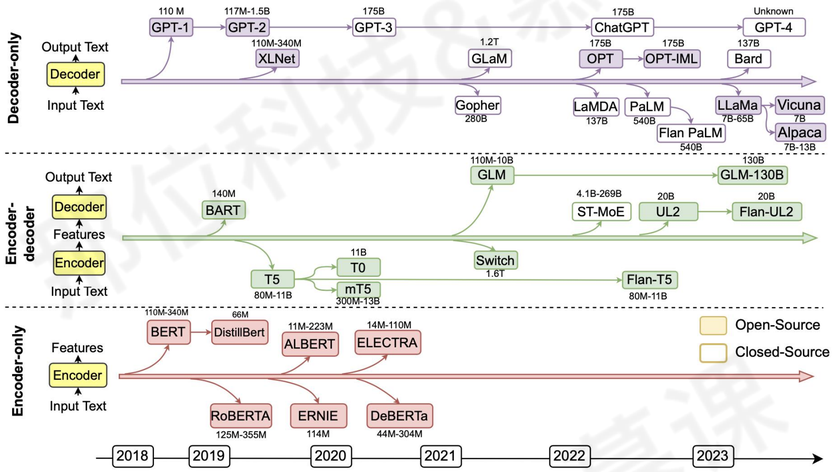
那位科技&慕课

知识图谱VS大模型







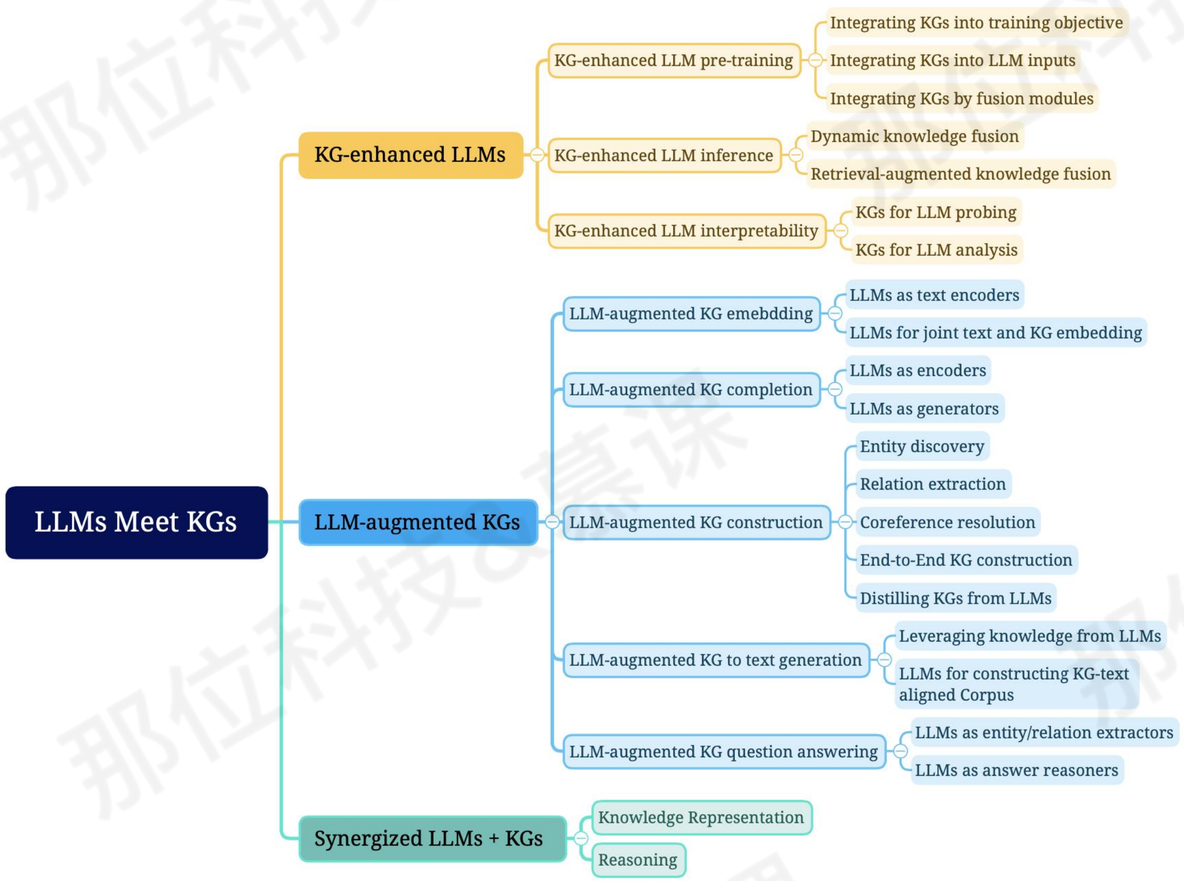


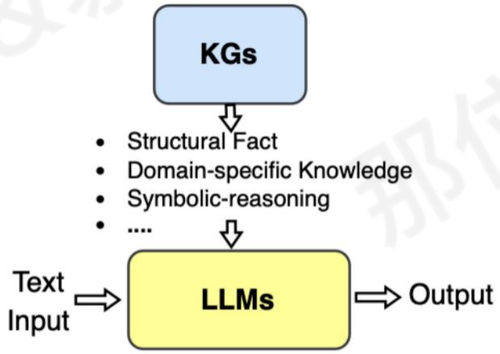
Name	Category	LLMs	KGs	URL
ChatGPT/GPT-4	Chat Bot	✓		https://shorturl.at/cmsE0
ERNIE 3.0	Chat Bot	✓	✓	https://shorturl.at/sCLV9
Bard	Chat Bot	✓	✓	https://shorturl.at/pDLY6
Firefly	Photo Editing	✓		https://shorturl.at/fkzJV
AutoGPT	AI Assistant	✓		https://shorturl.at/bkoSY
Copilot	Coding Assistant	✓		https://shorturl.at/lKLUV
New Bing	Web Search	✓		https://shorturl.at/bimps
Shop.ai	Recommendation	✓		https://shorturl.at/alCY7
Wikidata	Knowledge Base		✓	https://shorturl.at/lyMY5
KO	Knowledge Base		✓	https://shorturl.at/sx238
AliOpenKG	Recommendation		✓	https://shorturl.at/bmpDH
Doctor.ai	Health Care Assistant	✓	✓	https://shorturl.at/dhlK0

参考：https://arxiv.org/abs/2306.08302：Unifying Large Language Models and Knowledge Graphs：A Roadmap

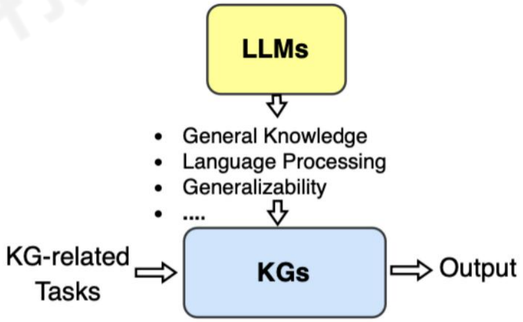
知识图谱与大模型融合的几个场景

知识图谱融合大模型

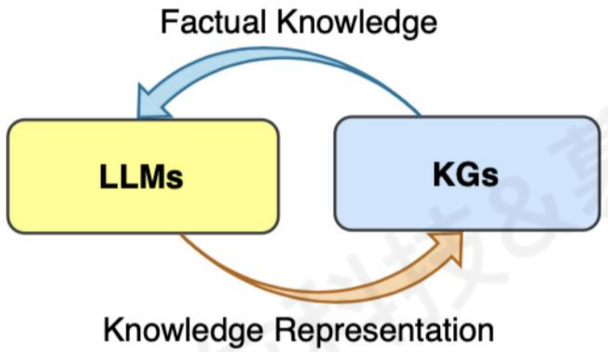




a. KG-enhanced LLMs



b. LLM-augmented KGs



c. Synergized LLMs + KGs

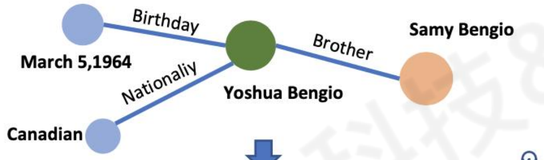
参考：https://arxiv.org/abs/2306.08302：Unifying Large Language Models and Knowledge Graphs：A Roadmap

知识图谱融合大模型

- 地址：https://arxiv.org/abs/2305.11952
- 知识图谱用于大模型训练前阶段：基于知识图谱生成SFT数据

Company	Date	Founder	Address
Microsoft	1975	Bill Gates	Redmond
Google	1998	Larry Page	Mountain View
Apple	1976	Steve Jobs	Cupertino

Microsoft was founded in 1975, with its headquarters located in Redmond, Washington. The company was founded by Bill Gates.



The birthday of Yoshua Bengio is March 5th, 1964. The nationality of Yoshua Bengio is Canadian. The brother of Yoshua Bengio is Samy Bengio.

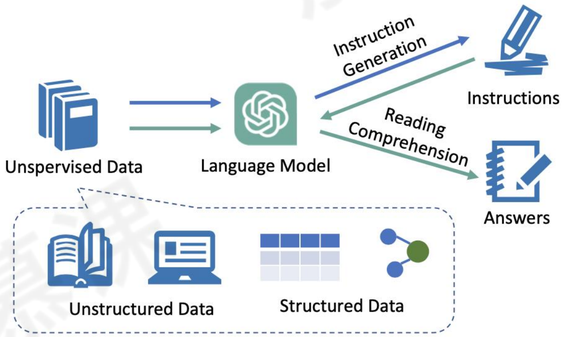


Figure 1: The pipeline of SELF-QA.

Instruction Generation Prompt

The background knowledge is:
{unsupervised knowledge data}

Please generate ten instruction questions as diverse as possible based on the content of the above article. These questions can be questions about facts or an understanding and evaluation of relevant content. Please assume that there is no corresponding article to refer to when asking questions, so do not use demonstrative pronouns such as "this" or "these" in the question.

Please generate questions in the following format:
1. Question: ...
2. Question: ...

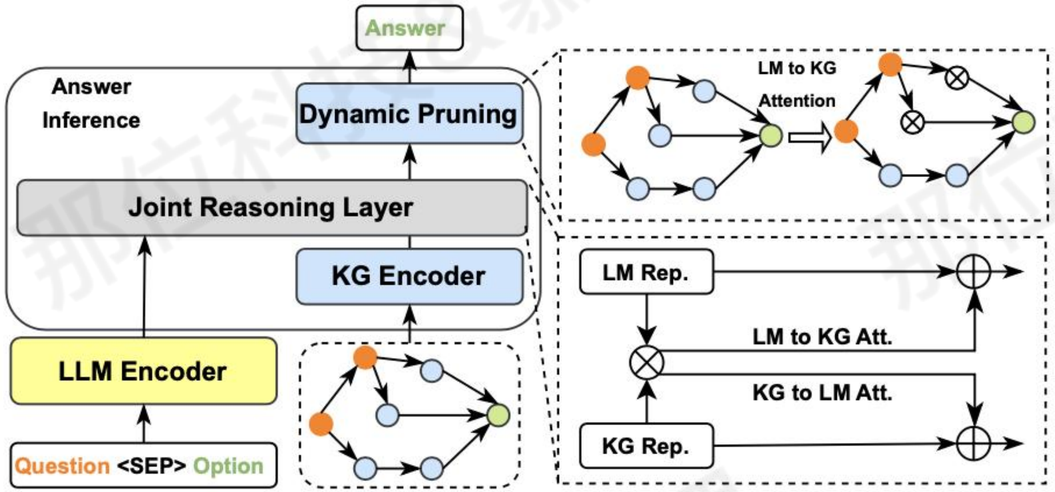
Reading Comprehension Prompt

The background knowledge is:
{unsupervised knowledge data}
Please answer the following question based on the content of the article above:
{the generated question}

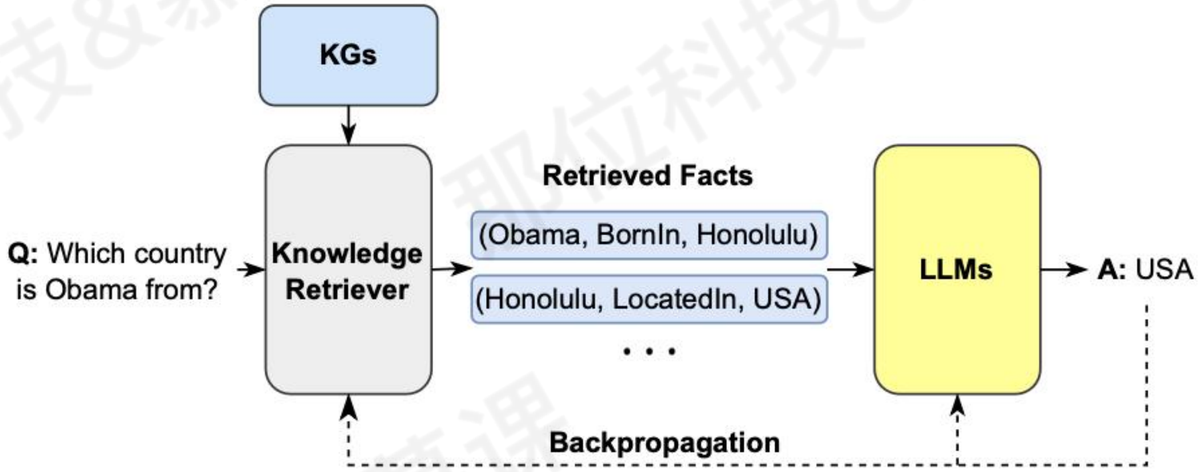
Please answer this question as thoroughly as possible, but do not change the key information in the original text, and do not include expressions such as "based on the above article" in the answer.

Please generate the corresponding answer in the following format:
Question: ...
Answer: ...

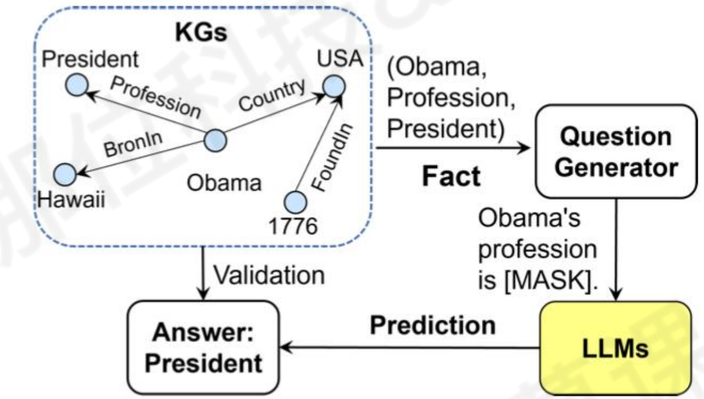
知识图谱融合大模型



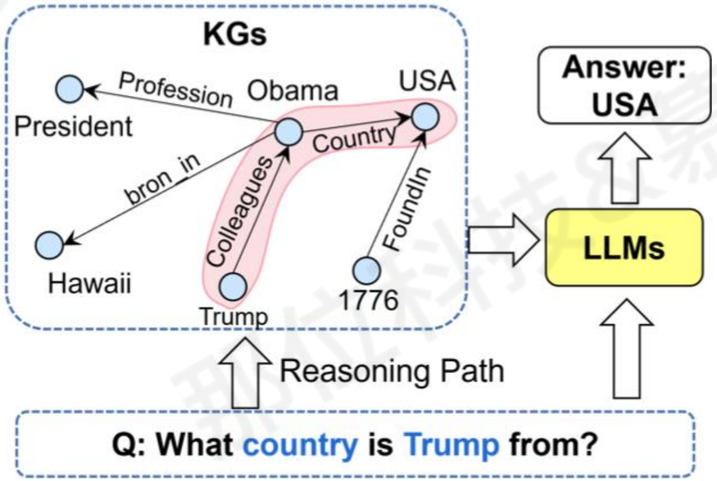
Dynamic knowledge graph fusion for LLM inference.



Retrieving external knowledge to enhance the LLM generation



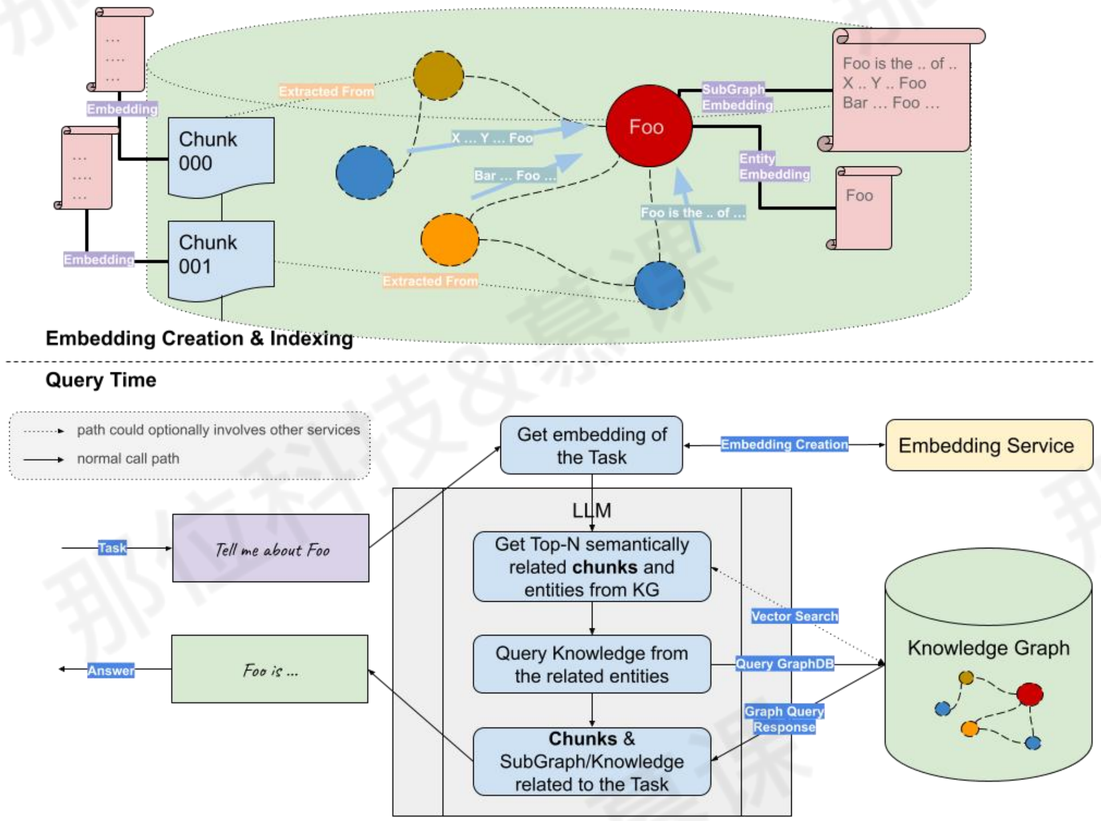
using knowledge graph for language model probing.

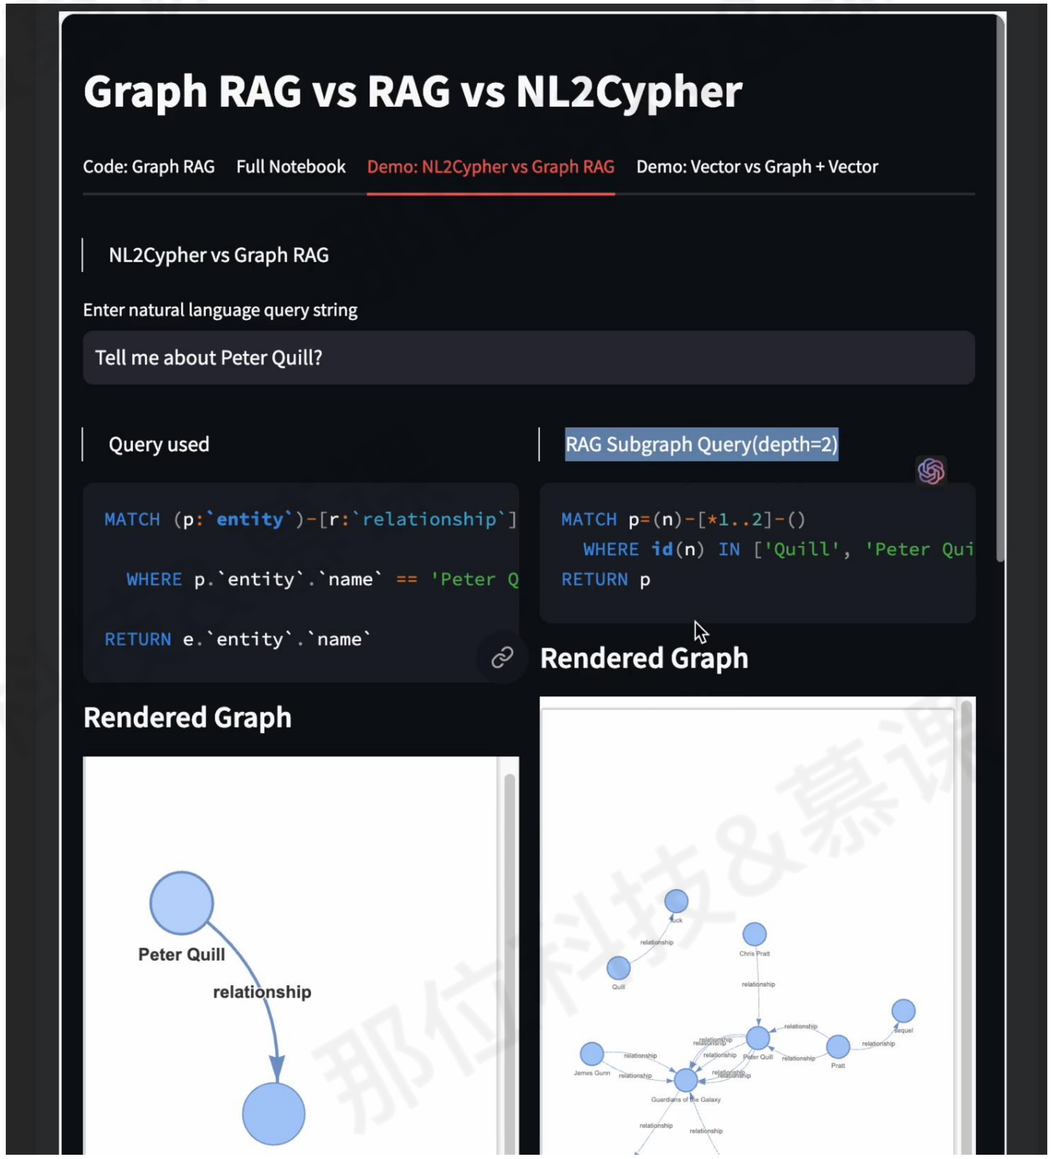


using knowledge graph for language model analysis.

知识图谱融合大模型

- 地址：https://siwei.io/graph-rag/
- 让知识图谱成为一路召回源增强大模型问答





知识图谱融合大模型

- 地址：https://ngql-gpt.siwei.io
- 地址：https://github.com/run-llama/llama_index/blob/71919f9dfa09e9628af8b3a59d497ad02a7a82f8/llama_index/query_engine/knowledge_graph_query_engine.py#L24
- 让大模型生成知识图谱查询语句cypher

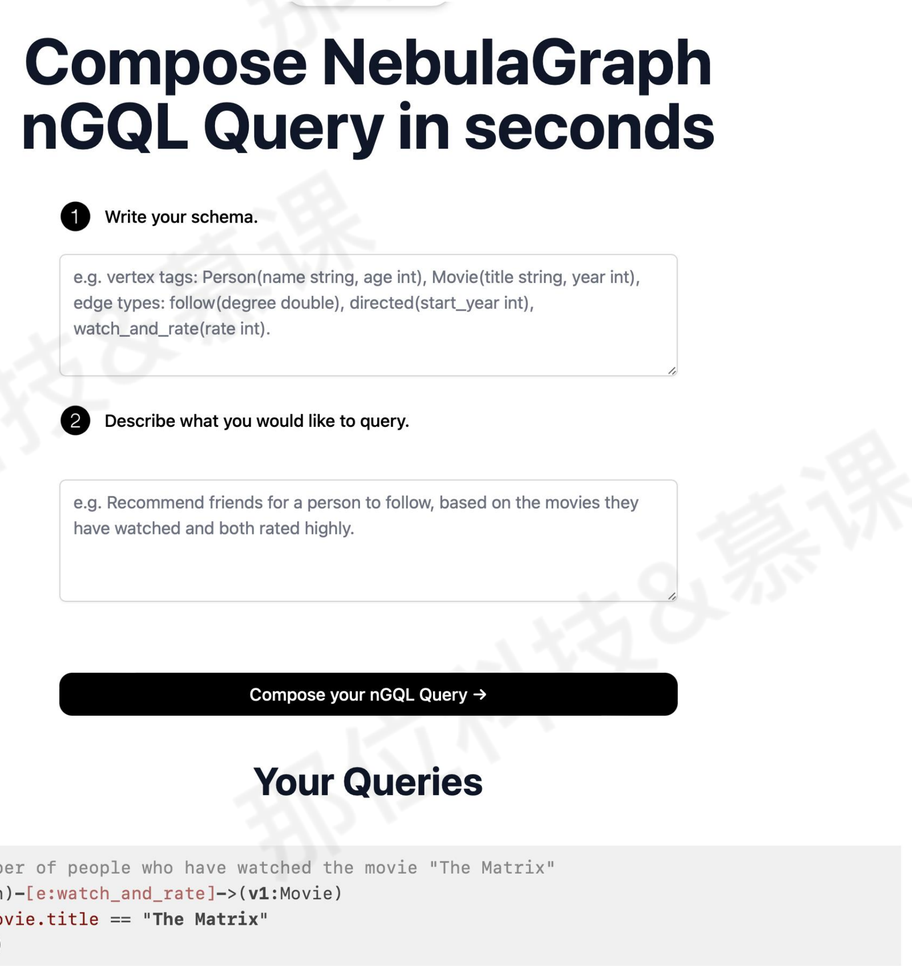
```
# Prompt
DEFAULT_NEBULAGRAPH_NL2CYPHER_PROMPT_TMPL = """
Generate NebulaGraph query from natural language.
Use only the provided relationship types and properties in the schema.
Do not use any other relationship types or properties that are not provided.
Schema:
---
{schema}
---
Note: NebulaGraph speaks a dialect of Cypher, comparing to standard Cypher:

1. it uses double equals sign for comparison: `==` rather than `=`
2. it needs explicit label specification when referring to node properties, i.e.
v is a variable of a node, and we know its label is Foo, v.`foo`.name is correct
while v.name is not.

For example, see this diff between standard and NebulaGraph Cypher dialect:
```diff
< MATCH (p:person)-[:directed]->(m:movie) WHERE m.name = 'The Godfather'
< RETURN p.name;
---
> MATCH (p:`person`)-[:directed]->(m:`movie`) WHERE m.`movie`.`name` == 'The Godfather'
> RETURN p.`person`.`name`;
```

Question: {query_str}

NebulaGraph Cypher dialect query:
```



利用大模型推理进行知识图谱构策略

知识图谱的优势和当前问题

那位科技

- **主要优势**
  - 一份好的知识图谱数据，可以为关键词扩充、领域精准问答、实体拓展等提供一手数据来源
  - 一份好的领域知识图谱数据，可以作为一个行业专家系统，一个专业的强规则库进行权威指导
  - 知识图谱中的图结构多跳信息，可以完成多跳推理、隐藏关系发现等任务
  - 知识图谱足够直观，足够醒目，可以作为现象的机理分析和可解释
  - 知识图谱作为一个领域的知识建模规范，可用于知识系统联合

- **利用大模型统一信息抽取任务，加速不同任务的统一处理**
- **利用大模型生成标注数据，减少人力成本，提升敏感场景项目交付**
- **利用大模型平替各环节抽取任务，提升模型性能**

那位科技&慕课

知识图谱的优势和当前问题

- **主要问题**
  - 整个生产流程过长，涉及到格式转换、本体定义、实体抽取、关系抽取、实体对齐，不够端到端
  - 多个具有级联错误的环节，加上上线要求的高标准，构建成本相对较高
  - 信息抽取环节需要有大量的标注数据，标注成本高
  - 知识图谱的领域属性较强，更多时候需要case by case，需要行业专家高度参与
  - 研发周期过长带来的时间成本问题，以及不同领域的迁移问题
  - 在解决实时性、准确性、全面性上的问题时，所需要花费的运行和维护成本较高

那位科技&慕课

知识图谱的优势和当前问题

- 利用大模型统一信息抽取任务，加速不同任务的统一处理
- 利用大模型生成标注数据，减少人力成本，提升敏感场景项目交付
- 利用大模型平替各环节抽取任务，提升模型性能

那位科技
那位科技&慕课

大模型用于数据标注

- 思想：**基于大模型完成数据标注和数据增强，加速知识图谱生产落地**
  - 利用ChatGPT来标注语料，然后再利用Bert等模型来训练的方式是不是奇怪？
  - ChatGPT用来做数据标注，再去训练模型，是不是有点本末倒置，为什么不直接ChatGPT 干下游任务？
    - 不同的场景对大模型的使用方式有明显差异，在数据敏感、数据不出网的场景下，可能成为必选项；
    - 在更偏垂直的下游任务中，全监督模型的方式能够取得更佳效果

- 效果：
  - https://github.com/howl-anderson/unlocking-the-power-of-llms
  - 《Exploring ChatGPT's Ability to Rank Content: A Preliminary Study on Consistency with Human Preferences》

那位科技&慕课

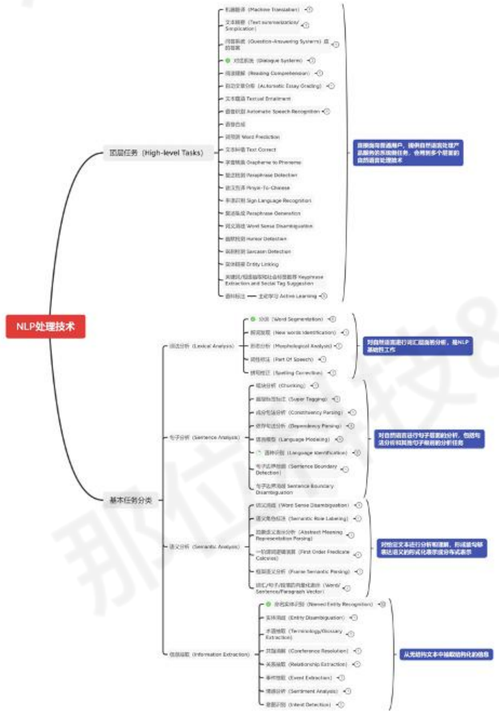
大模型用于数据标注

那位科技

Prompt

你是一个自然语言处理的语料增强程序，请理解并增强下面这个的语料。不要过度泛化：

文本	领域	实体映射
打开车门	设备控制	设备：车门
关闭空调	设备控制	设备：空调
导航到人民路	导航	POI：人民路
开车去郊野公园	导航	POI：郊野公园



语料扩充

文本	领域	实体映射
打开后备箱	设备控制	设备：后备箱
调高音量到80	设备控制	设备：音响，属性：音量，数值：80
导航到北京天安门广场	导航	POI：北京天安门广场
开启车辆防盗系统	设备控制	设备：防盗系统
显示明天的天气	天气查询	时间：明天
将客厅灯调暗一些	设备控制	设备：客厅灯，属性：亮度，数值：稍微暗一些
播放周杰伦的七里香	娱乐	歌手：周杰伦，歌曲：七里香
打开窗户	设备控制	设备：窗户
降低空调温度到25度	设备控制	设备：空调，属性：温度，数值：25
导航到附近的加油站	导航	POI：加油站
调整座椅到舒适的位置	设备控制	设备：座椅，属性：位置，数值：舒适
停止播放音乐	娱乐	动作：停止播放音乐
打电话给张三	通讯	对象：张三
导航到机场	导航	POI：机场
打开车窗	设备控制	设备：车窗
关闭车窗	设备控制	设备：车窗
升高座椅到合适的高度	设备控制	设备：座椅，属性：高度，数值：合适
显示最近的通知	提醒事项	类型：通知
播报今天的新闻	新闻	时间：今天
显示路况	导航	信息类型：路况
导航到附近的酒店	导航	POI：酒店
打开前灯	设备控制	设备：前灯
关闭后灯	设备控制	设备：后灯
设置提醒，下午3点有会议要参加	提醒事项	时间：下午3点，事件：参加会议
显示今天的日程	提醒事	

语料扩充

文本	领域	实体映射
打开行李箱	设备控制	设备：行李箱
调整窗帘至适宜的高度	设备控制	设备：窗帘，属性：高度，数值：适宜
导航到最近的医院	导航	POI：医院
播放薛之谦的歌曲	娱乐	歌手：薛之谦
打开车载空气净化器	设备控制	设备：车载空气净化器
关闭车载空气净化器	设备控制	设备：车载空气净化器
调高车座温至适宜的温度	设备控制	设备：车座，属性：温度，数值：适宜
导航到家	导航	POI：家
打开车顶天窗	设备控制	设备：车顶天窗
关闭车顶天窗	设备控制	设备：车顶天窗
显示今天的股票行情	财经	时间：今天，信息类型：股票行情
拨打紧急电话	通讯	动作：拨打紧急电话
导航到最近的超市	导航	POI：超市
调整空调风向至面部	设备控制	设备：空调，属性：风向，数值：面部
打开后备箱盖	设备控制	设备：后备箱盖
关闭后备箱盖	设备控制	设备：后备箱盖
调高车载音响的低音	设备控制	设备：车载音响，属性：低音，数值：稍微高一些
播报明天的天气	天气查询	时间：明天
显示附近的停车场信息	导航	POI：停车场，信息类型：附近
导航到最近的药店	导航	POI：药店
打开车载导航声音	设备控制	设备：车载导航，属性：声音，数值：打开

大模型之家

主谓宾三元组抽取

- GPT-4在学术标准数据集上测试性能虽然仍弱于全监督小模型（该结果为初步探究，仍需通过更大规模数据集及更完备评估方式验证），但其具备较强的泛化能力，可以抽取新的和较为复杂的知识，且可以通过文本指令的优化不断提高性能，这给快速构建领域知识图谱带来了福音。

- GPT-4可能在一定程度上并非依靠记忆实现知识抽取，而是通过指令学习和人类反馈具备了较强的可泛化知识抽取能力。

- 基于大模型指令可以同时从文本语料和参数空间抽取知识，进而提供了大模型时代构建知识图谱的新思路，可以降低知识图谱构建成本，也为通过知识图谱增强大模型（如结合Llama-Index等检索增强工具）提供了便利。

- GPT-4给少样本多模态知识抽取与推理带来了新的机遇与挑战。

那位科技&慕课

大模型用于知识图谱构建

大模型之家

三元组抽取

51

subject_type有：['官员','君主','百姓','地域','朝代','人物官职','人物别名','人物出生时间'], object_type有：['官员','君主','百姓','地域','朝代','人物官职','人物别名','人物出生时间'], relation有['上级','父亲','母亲','兄弟姐妹','丈夫','官职','别名','出生时间','属于','位于'],示例输入："这一年，海陵皇帝的儿子崇王元寿逝世"，示例输出：[{'subject_type':'君主','subject':'海陵皇帝','relation':'儿子','object_type':'官员','object':'元寿','text':'这一年，海陵皇帝的儿子崇王元寿逝世'},{'subject_type':'官员','subject':'元寿','relation':'官职','object_type':'人物官职','object':'崇王','text':'这一年，海陵皇帝的儿子崇王元寿逝世'}]。若输入为："于是接纳宗本的儿子莎鲁嗏、宗固的儿子胡里剌和胡失打、秉德的弟弟磕里等人的妻子到宫中。"，请输出

[{'subject_type':'君主','subject':'接纳宗本','relation':'儿子','object_type':'官员','object':'莎鲁嗏','text':'于是接纳宗本的儿子莎鲁嗏到宫中'},{'subject_type':'君主','subject':'宗固','relation':'儿子','object_type':'官员','object':'胡里剌和胡失打','text':'于是宗固的儿子胡里剌和胡失打到宫中'},{'subject_type':'君主','subject':'秉德','relation':'弟弟','object_type':'官员','object':'磕里','text':'于是秉德的弟弟磕里到宫中'},{'subject_type':'官员','subject':'磕里等人','relation':'妻子','object_type':'百姓','object':'到宫中','text':'于是秉德的弟弟磕里等人的妻子到宫中'}]。

51

若输入为："二日，海陵帝立他的儿子光英为皇太子，五日，向中外诏告这一消息。"，请输出

[{'subject_type':'君主','subject':'海陵帝','relation':'儿子','object_type':'官员','object':'光英','text':'二日，海陵帝立他的儿子光英为皇太子'},{'subject_type':'官员','subject':'光英','relation':'官职','object_type':'人物官职','object':'皇太子','text':'二日，海陵帝立他的儿子光英为皇太子'}]。

Try again

参考：朱雨琦、张宁豫，基于GPT-4的知识图谱构建能力评测， https://blog.csdn.net/TgqDT3gGaMdkHasLZv/article/details/129905368

那位科技&慕课

大模型用于知识图谱构建

大模型之家

实体识别

假设我有个实体识别的任务，要求从一段文本中识别出人物、地名、机构名。例如，给定输入“刘焕勇目前在北京市工作，工作单位是360人工智能研究院”，输出的结果为：人物：”刘焕勇“，地名：”北京市“，机构名：”360人工智能研究院“。 那么你帮我预测下，给定输入“在天津生活了大半辈子的孙权，现在被调到林业局工作了”，输出的结果是什么?

假设我有个实体识别的任务，要求从一段文本中识别出人物、地名、机构名。例如，给定输入“刘焕勇目前在北京市工作，工作单位是360人工智能研究院”，输出的结果为：人物：”刘焕勇“，地名：”北京市“，机构名：”360人工智能研究院“。

给定输入“在天津生活了大半辈子的孙权，现在被调到林业局工作了”，输出的结果可能如下：

人物：”孙权“
地名：”天津“
机构名：”林业局“

请注意，这仅是一个示例输出，实际结果可能会有所不同，这取决于所使用的实体识别算法和模型的精度。

参考：朱雨琦、张宁豫,基于GPT-4的知识图谱构建能力评测， https://blog.csdn.net/TgqDT3gGaMdkHasLZv/article/details/129905368

那位科技

因果关系抽取

```
prompt=[
    "请抽出句子中包含"影响"关系的三元组：示例输入：["未来随着国际民航业务的逐渐复苏，境外市场需求将恢复之疫情前水平","双碳政策牵引下，风电、核
        示例输出：[{sub:'国际民航业务', pre:'影响',obj:'境外市场需求'text:'未来随着国际民航业务的逐渐复苏，境外市场需求将恢复之疫情前水平
        输入为："根据中信证券研究部宏观组的观点，伴随疫苗逐步推出，全球经济有望实现共振复苏，并预测全球经济在2021年有望增长5.4%，同时经济的复
    ,

    "输入为："IaaS服务的出现，帮助企业客户实现了底层基础硬件设施的云化，而借助具有弹性、灵活性的IaaS层资源，基础软件市场亦在快速发生变化",请
    ,
    "输入为："考虑到明年宏观经济复苏推动用户需求的恢复以及5G网络建设、5G终端价格下探带来的5G换机潮等，我们预计明年全球智能手机销量有望实现双位

        ]
```

```
Chatbot:
输出：[{sub:'疫苗', pre:'影响',obj:'全球经济',text:'伴随疫苗逐步推出，全球经济有望实现共振复苏'},{sub:'全球经济', pre:'影响',obj:'通胀',text:'全球经济在2021年有望增长5.4%，同时经济的复苏将带来
Chatbot:
输出：[{sub:'IaaS服务', pre:'影响',obj:'企业客户',text:'IaaS服务的出现，帮助企业客户实现了底层基础硬件设施的云化'},{sub:'IaaS层资源', pre:'影响',obj:'基础软件市场',text:'借助具有弹性、灵活性的
Chatbot:
输出：[{sub:'宏观经济复苏', pre:'影响',obj:'用户需求',text:'考虑到明年宏观经济复苏推动用户需求的恢复'},{sub:'5G网络建设', pre:'影响',obj:'5G换机潮',text:'5G网络建设、5G终端价格下探带来的5G换机
```

参考：朱雨琦、张宁豫，基于GPT—4的知识图谱构建能力评测， https://blog.csdn.net/TgqDT3gGaMdkHasLZv/article/details/129905368

大模型用于知识图谱构建

实现原理：将零样本IE任务转变为一个两阶段框架的多轮问答问题（Chat IE），通过制定实体关系三元组抽取、命名实体识别和事件抽取任务，并为每个任务设计2个步骤的prompt-pattern，多轮抽取：

- 第一步用于识别指定类型；
- 第二步用于识别指定类型的值。将抽取的任务定义（抽取要素）进行prompt填充，然后调用ChatGPT接口
- 在取得结果后进行规则解析，结构化相应答案。

参考：https://github.com/cocacola-lab/ChatIE；https://arxiv.org/pdf/2302.10205.pdf：《Zero-Shot Information Extraction via Chatting with ChatGPT》

大模型用于知识图谱构建

任务	输入文本	输出
命名实体识别	《红楼梦》是中央电视台和中国电视剧制作中心根据中国古典文学名著《红楼梦》摄制于1987年的一部古装连续剧，由王扶林导演，周汝昌、王蒙、周岭等多位红学家参与制作。	[{'E': 'TV Series', 'W': '红楼梦'}, {'E': 'Director', 'W': '王扶林'}, {'E': 'Actor', 'W': '周汝昌'}, {'E': 'Actor', 'W': '王蒙'}, {'E': 'Actor', 'W': '周岭'}]
关系抽取	孔正锡，导演，2005年以一部温馨的爱情电影《长腿叔叔》敲开电影界大门 (需指定头尾实体和实体类型)	导演
事件抽取	历经4小时51分钟的体力、意志力鏖战，北京时间9月9日上午纳达尔在亚瑟·阿什球场，以7比5、6比3、5比7、4比6和6比4击败赛会5号种子俄罗斯球员梅德韦杰夫，夺得了2019年美国网球公开赛男单冠军。	event_list: [event_type: [arguments: [role: 纳达尔, argument: 夺得2019年美国网球公开赛男单冠军], [role: 梅德韦杰夫, argument: 被纳达尔击败]], [event_type: [arguments: [role: 纳达尔, argument: 以7比5、6比3、5比7、4比6和6比4击败梅德韦杰夫]], [event_type: [arguments: [role: 纳达尔, argument: 历经4小时51分钟的体力、意志力鏖战]], [event_type: [arguments: [role: 纳达尔, argument: 在亚瑟·阿什球场]], [event_type: [arguments: [role: 梅德韦杰夫, argument: 赛会5号种子俄罗斯球员]]]]
联合关系抽取	《没有你的夜晚》是歌手欧阳菲菲演唱的歌曲，出自专辑《拥抱》	[['《没有你的夜晚》', '演唱者', '欧阳菲菲'], ['《没有你的夜晚》', '出自专辑', '《拥抱》']]

参考：https://github.com/cocacola-lab/ChatIE；https://arxiv.org/pdf/2302.10205.pdf：《Zero-Shot Information Extraction via Chatting with ChatGPT》

大模型用于知识图谱构建

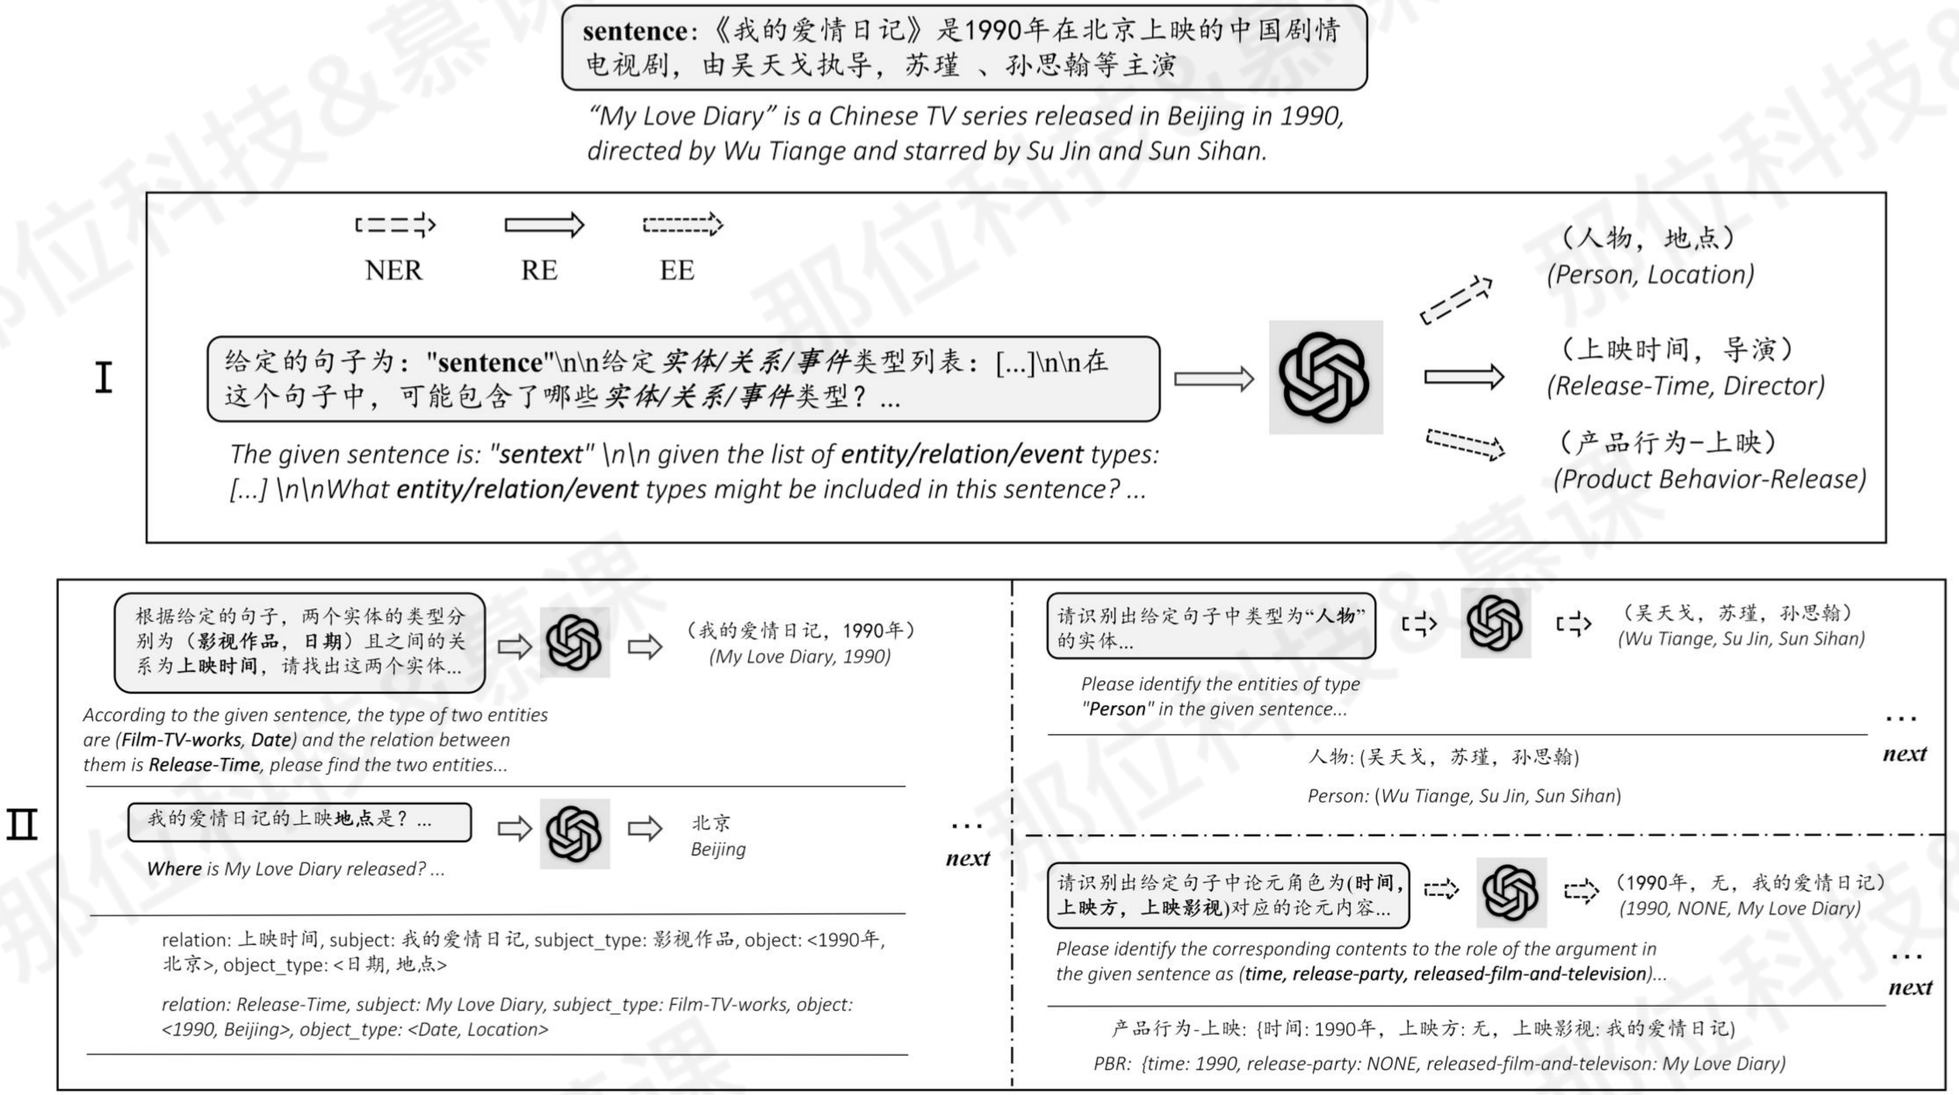


Figure 1: Illustration for the framework. For convenience, we use the samples of DuIE2.0 as examples of three tasks to show.

参考：https://github.com/cocacola-lab/ChatIE；https://arxiv.org/pdf/2302.10205.pdf：《Zero-Shot Information Extraction via Chatting with ChatGPT》

大模型用于知识图谱构建

那位科技

STAGE I

Question:
Suppose you are an entity-relationship triple extraction model. I'll give you list of head entity types: subject_types, list of tail entity types: object_types, list of relations: relations. Give you a sentence, please extract the subject and object in the sentence based on these three lists, and form a triplet in the form of (subject, relation, object).

The given sentence is "Bono said that President Jacques Chirac of France had spoken eloquently of the need to support Africa , though he added that France had not yet come through with the resources ."

relations:['location-located_in','administrative_division-country', 'person-place_lived', 'person-company', 'person-nationality', 'company-founders', 'country-administrative_divisions', 'person-children', 'country-capital','deceased_person-place_of_death','neighborhood-neighborhood_of', 'person-place_of_birth']

subject_types: ['organization', 'person', 'location', 'country']

object_types: ['person', 'location', 'country', 'organization', 'city']

In the given sentence, what triples might be contained? Please answer in the form (subject, relation, object):

Expected Output: [(Jacques Chirac, person-nationality, France)] ***Output:*** []

关系抽取

STAGE I

Question:
I'm going to give you a sentence and ask you to identify the entities and label the entity category. There will only be 4 types of entities: ['LOC', 'MISC', 'ORG', 'PER']. Please present your results in list form. "Japan then laid siege to the Syrian penalty area and had a goal disallowed for offside in the 16th minute." Make the list like: ['entity name1', 'entity type1'],['entity name2', 'entity type2'].....

Expected Output: ["Japan", "LOC"], ["Syrian", "MISC"] ***Output:*** []

实体识别

STAGE I

Question:
The list of argument roles corresponding to the event type 'Contact:Phone-Write' is ['Entity', 'Time'], The list of argument roles corresponding to the event type 'Business:Declare-Bankruptcy' is ['Org', 'Time', 'Place'], The list of argument roles corresponding to the event type 'Justice:Arrest-Jail' is ['Person', 'Agent', 'Crime', 'Time', 'Place'], The list of argument roles corresponding to the event type 'Life:Die' is ['Agent', 'Victim', 'Instrument', 'Time', 'Place'], The list of argument roles corresponding to the event type 'Personnel:Nominate' is ['Person', 'Agent', 'Position', 'Time', 'Place'], The list of argument roles corresponding to the event type 'Conflict:Attack' is ['Attacker', 'Target', 'Instrument', 'Time', 'Place'], The list of argument roles corresponding to the event type 'Justice:Sue' is ['Plaintiff', 'Defendant', 'Adjudicator', 'Crime', 'Time', 'Place'], The list of argument roles corresponding to the event type 'Life:Marry' is ['Person', 'Time', 'Place']. Give a sentence:"What I do know is Saddam Hussein has butchered over a million of his own citizens.", please extract the event arguments according to the argument roles, and return them in the form of a table.The header of the table is 'event type', 'argument role', 'argument content'. If no argument role has a corresponding argument content, the argument content returns "None".

Expected Output: "event_type": "Life:Die", "arguments": ["role": "Victim", "argument": "over a million of his own citizens" , { "role": "Agent", "argument": "Saddam Hussein" } ***Output:*** None

事件抽取识别

参考：https://github.com/cocacola-lab/ChatIE；https://arxiv.org/pdf/2302.10205.pdf

大模型用于知识图谱构建

那位科技

Question:
Given sentence: "Japan then laid siege to the Syrian penalty area and had a goal disallowed for offside in the 16th minute." The known entity types are: ['LOC', 'MISC', 'ORG', 'PER']. Please answer: What types of entities are included in this sentence?

Expected Output: LOC, MISC ***Output:*** LOC, MISC

Question:
According to the sentence above, please output the entities of 'LOC' in the form of list like: ['entity name1', 'entity type1'], ['entity name2', 'entity type2']......

According to the sentence above, please output the entities of 'MISC' in the form of list like: ['entity name1', 'entity type1'], ['entity name2', 'entity type2']......

Expected Output: ["Japan", "LOC"], ["Syrian", "MISC"]***Output:*** ["Japan", "LOC"], ["Syrian", "LOC"]

关系抽取

Question:
Given sentence: "Japan then laid siege to the Syrian penalty area and had a goal disallowed for offside in the 16th minute." The known entity types are: ['LOC', 'MISC', 'ORG', 'PER']. Please answer: What types of entities are included in this sentence?

Expected Output: LOC, MISC ***Output:*** LOC, MISC

Question:
According to the sentence above, please output the entities of 'LOC' in the form of list like: ['entity name1', 'entity type1'], ['entity name2', 'entity type2']......

According to the sentence above, please output the entities of 'MISC' in the form of list like: ['entity name1', 'entity type1'], ['entity name2', 'entity type2']......

Expected Output: ["Japan", "LOC"], ["Syrian", "MISC"]***Output:*** ["Japan", "LOC"], ["Syrian", "LOC"]

实体识别

Question:
The list of event types: ['Life:Die', 'Justice:Arrest-Jail', 'Contact:Phone-Write', 'Life:Marry', 'Conflict:Attack', 'Personnel:Nominate', 'Business:Declare-Bankruptcy', 'Justice:Sue']

Give a sentence: "What I do know is Saddam Hussein has butchered over a million of his own citizens."
What types of events are included in this sentence?
Please return the most likely answer according to the list of event types above.
Require the answer in the form: Event type

Expected Output: Life:Die ***Output:*** Life:Die

Question:
The list of argument roles corresponding to the event type 'Life: Die' is ['Agent', 'Victim', 'Instrument', 'Time', 'Place'].
please extract the event arguments in the given sentence according to the argument roles, and return them in the form of a table. The header of the table is 'event type', 'argument role', 'argument content'.
If no argument role has a corresponding argument content, the argument content returns "None".

Expected Output: "arguments": ["role": "Victim", "argument": "over a million of his own citizens" , { "role": "Agent", "argument": "Saddam Hussein" } ***Output:*** "arguments": ["role": "Victim", "argument": "over a million of his own citizens" , { "role": "Agent", "argument": "Saddam Hussein" }

事件抽取识别

参考：https://github.com/cocacola-lab/ChatIE；https://arxiv.org/pdf/2302.10205.pdf

大模型用于知识图谱构建

```
df_nert = {'chinese': ['组织机构', '地点', '人物'],
           'english': ['PER', 'LOC', 'ORG', 'MISC'],}
```

```
ner_s1_p = {'chinese': '''给定的句子为："{}"\n\n给定实体类型列表：{}\n\n在这个句子中，可能包含了哪些实体类型？\n如果不存在则回答：无\n按照元组形式回复，如（实体类型1，实体类型2，……）：''','english': '''The given sentence is "{}"\n\nGiven a list of entity types: {}\n\nWhat entity types may be included in this sentence?\nIf not present, answer: none.\nRespond as a list, e.g. [
entity type 1, entity type 2, ......]:'''}
ner_s2_p = { 'chinese': '''根据给定的句子，请识别出其中类型是"{}"的实体。\n如果不存在则回答：无\n按照表格形式回复，表格有两列且表头为（实体类型，实体名称）：''','english': '''According to the given sentence, please identify the entity whose type is "{}".\nIf not present, answer: none.\nRespond in the form of a table with two columns and a header of (entity type, entity name):'''
```

实体识别任务

参考：https://github.com/cocacola-lab/ChatIE；https://arxiv.org/pdf/2302.10205.pdf

大模型用于知识图谱构建

```
df_ret = {
    'english': {
            'location-located_in': ['location', 'location'],
            'administrative_division-country': ['location', 'country'],
            'person-place_lived': ['person', 'location'],
            'person-company': ['person', 'organization'],
            'person-nationality': ['person', 'country'],
            'company-founders': ['organization', 'person'],
            'country-administrative_divisions': ['country', 'location'],
            'person-children': ['person', 'person'],
            'country-capital': ['country', 'city'],
            'deceased_person-place_of_death': ['person', 'location'],
            'neighborhood-neighborhood_of': ['location', 'location'],
            'person-place_of_birth': ['person', 'location'],
            },
    'chinese': {'所属专辑': ['歌曲', '音乐专辑'], '成立日期': ['机构', 'Date'], '海拔': ['地点', 'Number'], '官方语言': ['国家', '语言'],
    '占地面积': ['机构', 'Number'], '父亲': ['人物', '人物'],
                '歌手': ['歌曲', '人物'], '制片人': ['影视作品', '人物'], '导演': ['影视作品', '人物'], '首都': ['国家', '城市'], '主演':
                ['影视作品', '人物'], '董事长': ['企业', '人物'], '祖籍': ['人物', '地点'],
                '妻子': ['人物', '人物'], '母亲': ['人物', '人物'], '气候': ['行政区', '气候'], '面积': ['行政区', 'Number'], '主角':
                ['文学作品', '人物'], '邮政编码': ['行政区', 'Text'], '简称': ['机构', 'Text'],
                '出品公司': ['影视作品', '企业'], '注册资本': ['企业', 'Number'], '编剧': ['影视作品', '人物'], '创始人': ['企业', '人物'],
                '毕业院校': ['人物', '学校'], '国籍': ['人物', '国家'],
                '专业代码': ['学科专业', 'Text'], '朝代': ['历史人物', 'Text'], '作者': ['图书作品', '人物'], '作词': ['歌曲', '人物'],
                '所在城市': ['景点', '城市'], '嘉宾': ['电视综艺', '人物'], '总部地点': ['企业', '地点'],
                '人口数量': ['行政区', 'Number'], '代言人': ['企业/品牌', '人物'], '改编自': ['影视作品', '作品'], '校长': ['学校', '人物'],
                '丈夫': ['人物', '人物'], '主持人': ['电视综艺', '人物'], '主题曲': ['影视作品', '歌曲'],
                '修业年限': ['学科专业', 'Number'], '作曲': ['歌曲', '人物'], '号': ['历史人物', 'Text'], '上映时间': ['影视作品',
                'Date'], '票房': ['影视作品', 'Number'], '饰演': ['娱乐人物', '人物'], '配音': ['娱乐人物', '人物'], '获奖': ['娱乐人物',
                '奖项']
                }
}
```

```
re_s1_p = {
    'chinese': '''给定的句子为："{}"\n\n给定关系列表：{}\n\n在这个句子中，可能包含了哪些关系？\n请给出关系列表中的关系。\n如果不存在则回答：无\n按照元组形式回复，如（关系1，关系2，……）：''',

    'english': '''The given sentence is "{}"\n\nList of given relations: {}\n\nWhat relations in the given list might be included in this given sentence?\nIf not present, answer: none.\nRespond as a tuple, e.g. (relation 1, relation 2, ......):''',
}

re_s2_p = {
    'chinese': '''根据给定的句子，两个实体的类型分别为（{}，{}）且之间的关系为{}，请找出这两个实体，如果有多组，则按组全部列出。\n如果不存在则回答：无\n按照表格形式回复，表格有两列且表头为（{}，{}）：''',
'english': '''According to the given sentence, the two entities are of type ('{}', '{}') and the relation between them is '{}', find the two entities and list them all by group if there are multiple groups.\nIf not present, answer: none.\nRespond in the form of a table with two columns and a header of ('{}', '{}'):''',
}`
```

关系抽取任务

参考：https://github.com/cocacola-lab/ChatIE；https://arxiv.org/pdf/2302.10205.pdf

大模型用于知识图谱构建

那位科技

事件抽取任务

```
df_eet = {
    'chinese': {'灾害/意外-坠机': ['时间', '地点', '死亡人数', '受伤人数'], '司法行为-举报': ['时间', '举报发起方', '举报对象'], '财经/交易-涨价': ['时间',
    '涨价幅度', '涨价物', '涨价方'], '组织关系-解雇': ['时间', '解雇方', '被解雇人员'], '组织关系-停职': ['时间', '所属组织', '停职人员'], '财经/交易-加息': ['时间',
    '加息幅度', '加息机构'], '交往-探班': ['时间', '探班主体', '探班对象'], '人生-怀孕': ['时间', '怀孕者'], '组织关系-辞/离职': ['时间', '离职者', '原所属组织'],
    '组织关系-裁员': ['时间', '裁员方', '裁员人数'], '灾害/意外-车祸': ['时间', '地点', '死亡人数', '受伤人数'],
                '人生-离婚': ['时间', '离婚双方'], '司法行为-起诉': ['时间', '被告', '原告'], '竞赛行为-禁赛': ['时间', '禁赛时长', '被禁赛人员', '禁赛机构'],
                '人生-婚礼': ['时间', '地点', '参礼人员', '结婚双方'], '财经/交易-涨停': ['时间', '涨停股票'], '财经/交易-上市': ['时间', '地点', '上市企业',
                '融资金额'], '组织关系-解散': ['时间', '解散方'], '财经/交易-跌停': ['时间', '跌停股票'], '财经/交易-降价': ['时间', '降价方', '降价物',
                '降价幅度'], '组织行为-罢工': ['时间', '所属组织', '罢工人数', '罢工人员'], '司法行为-开庭': ['时间', '开庭法院', '开庭案件'],
                '竞赛行为-退役': ['时间', '退役者'], '人生-求婚': ['时间', '求婚者', '求婚对象'], '人生-庆生': ['时间', '生日方', '生日方年龄', '庆祝方'],
                '交往-会见': ['时间', '地点', '会见主体', '会见对象'], '竞赛行为-退赛': ['时间', '退赛赛事', '退赛方'], '交往-道歉': ['时间', '道歉对象', '道歉者'],
                '司法行为-入狱': ['时间', '入狱者', '刑期'], '组织关系-加盟': ['时间', '加盟者', '所加盟组织'], '人生-分手': ['时间', '分手双方'], '灾害/意外-袭击':
                ['时间', '地点', '袭击对象', '死亡人数', '袭击者', '受伤人数'], '灾害/意外-坍/垮塌': ['时间', '坍塌主体', '死亡人数', '受伤人数'],
                '组织关系-解约': ['时间', '被解约方', '解约方'], '产品行为-下架': ['时间', '下架产品', '被下架方', '下架方'], '灾害/意外-起火': ['时间', '地点',
                '死亡人数', '受伤人数'], '灾害/意外-爆炸': ['时间', '地点', '死亡人数', '受伤人数'], '产品行为-上映': ['时间', '上映方', '上映影视'], '人生-订婚':
                ['时间', '订婚主体'], '组织关系-退出': ['时间', '退出方', '原所属组织'], '交往-点赞': ['时间', '点赞方', '点赞对象'], '产品行为-发布': ['时间',
                '发布产品', '发布方'], '人生-结婚': ['时间', '结婚双方'], '组织行为-闭幕': ['时间', '地点', '活动名称'],
                '人生-死亡': ['时间', '地点', '死者年龄', '死者'], '竞赛行为-夺冠': ['时间', '冠军', '夺冠赛事'], '人生-失联': ['时间', '地点', '失联者'], '财经/
                交易-出售/收购': ['时间', '出售方', '交易物', '出售价格', '收购方'], '竞赛行为-晋级': ['时间', '晋级方', '晋级赛事'], '竞赛行为-胜负': ['时间',
                '败者', '胜者', '赛事名称'], '财经/交易-降息': ['时间', '降息幅度', '降息机构'], '组织行为-开幕': ['时间', '地点', '活动名称'], '司法行为-拘捕':
                ['时间', '拘捕者', '被拘捕者'], '交往-感谢': ['时间', '致谢人', '被感谢人'], '司法行为-约谈': ['时间', '约谈对象', '约谈发起方'],
                '灾害/意外-地震': ['时间', '死亡人数', '震级', '震源深度', '震中', '受伤人数'], '人生-产子/女': ['时间', '产子者', '出生者'], '财经/交易-融资':
                ['时间', '跟投方', '领投方', '融资轮次', '融资金额', '融资方'], '司法行为-罚款': ['时间', '罚款对象', '执法机构', '罚款金额'], '人生-出轨': ['时间',
                '出轨方', '出轨对象'], '灾害/意外-洪灾': ['时间', '地点', '死亡人数', '受伤人数'], '组织行为-游行': ['时间', '地点', '游行组织', '游行人数'],
                '司法行为-立案': ['时间', '立案机构', '立案对象'], '产品行为-获奖': ['时间', '获奖人', '奖项', '颁奖机构'], '产品行为-召回': ['时间', '召回内容',
                '召回方']},
    'english': {'Justice:Appeal': ['Defendant', 'Adjudicator', 'Crime', 'Time', 'Place'], 'Justice:Extradite': ['Agent', 'Person', 'Destination',
    'Origin', 'Crime', 'Time'], 'Justice:Acquit': ['Defendant', 'Adjudicator', 'Crime', 'Time', 'Place'], 'Life:Be-Born': ['Person', 'Time',
    'Place'], 'Life:Divorce': ['Person', 'Time', 'Place'], 'Personnel:Nominate': ['Person', 'Agent', 'Position', 'Time', 'Place'], 'Life:Marry':
    ['Person', 'Time', 'Place'], 'Personnel:End-Position': ['Person', 'Entity', 'Position', 'Time', 'Place'],
                'Justice:Pardon': ['Defendant', 'Prosecutor', 'Adjudicator', 'Crime', 'Time', 'Place'], 'Business:Merge-Org': ['Org', 'Time',
                'Place'], 'Conflict:Attack': ['Attacker', 'Target', 'Instrument', 'Time', 'Place'], 'Justice:Charge-Indict': ['Defendant',
                'Prosecutor', 'Adjudicator', 'Crime', 'Time', 'Place'], 'Personnel:Start-Position': ['Person', 'Entity', 'Position', 'Time',
                'Place'], 'Business:Start-Org': ['Agent', 'Org', 'Time', 'Place'], 'Business:End-Org': ['Org', 'Time', 'Place'],
                'Life:Injure': ['Agent', 'Victim', 'Instrument', 'Time', 'Place'], 'Justice:Fine': ['Entity', 'Adjudicator', 'Money', 'Crime',
                'Time', 'Place'], 'Justice:Sentence': ['Defendant', 'Adjudicator', 'Cr
                'Transaction:Transfer-Money': ['Giver', 'Recipient', 'Beneficiary', 'M
                'Agent', 'Crime', 'Time', 'Place'], 'Justice:Sue': ['Plaintiff', 'Defe
                'Justice:Arrest-Jail': ['Person', 'Agent', 'Crime', 'Time', 'Place'],
                'Adjudicator', 'Crime', 'Time', 'Place'], 'Movement:Transport': ['Agen
                'Contact:Meet': ['Entity', 'Time', 'Place'], 'Personnel:Elect': ['Pers
                'Business:Declare-Bankruptcy': ['Org', 'Time', 'Place'], 'Transaction:
                'Artifact', 'Price', 'Time', 'Place'],
                'Justice:Release-Parole': ['Person', 'Entity', 'Crime', 'Time', 'Place
                'Contact:Phone-Write': ['Entity', 'Time'], 'Justice:Convict': ['Defend
                ['Agent', 'Victim', 'Instrument', 'Time', 'Place']},
}
```

```
ee_s1_p = {
    'chinese': '''给定的句子为："{}"\n\n给定事件类型列表：{}\n\n在这个句子中，可能包含了哪些事件类型？\n请给出事件类型列表中的事件类型。\n如果不存在则回答：无\n按照元组形式回复，如（事件类型1，事件类型2，……）：''',
    'english': '''The given sentence is "{}"\n\nGiven a list of event types: {}\n\nWhat event types in the given list might be included in this given sentence?\nIf not present, answer: none.\nRespond as a tuple, e.g. (event type 1, event type 2, ......):'''
}


ee_s2_p = {
    'chinese': '''事件类型"{}"对应的论元角色列表为：{}。\n在给定的句子中，根据论元角色提取出事件论元。\n如果论元角色没有相应的论元内容，则论元内容回答：无\n按照表格形式回复，表格有两列且表头为（论元角色，论元内容）：''',
    'english': '''The list of argument roles corresponding to event type "{}" is: {}.\nIn the given sentence, extract event arguments according to their role.\nIf the argument role does not have a corresponding argument content, then the argument content answer: None\nRespond in the form of a table with two columns and a header of (argument role, argument content):'''
}
```

参考：https://github.com/cocacola-lab/ChatIE；https://arxiv.org/pdf/2302.10205.pdf

思想：针对特定任务，设定若干个正确用例，组成prompt后，可以增强生成结果，采用2轮QA的方法，完成信息抽取任务。其中需要构造sentence_with_ie_prompt和in-context learning上下文。

1）sentence_with_cls_prompt

sentence_with_cls_prompt = CLS_PATTERN.format(sentence)，先对句子进行实体类型识别，构造prompt:

```
CLS_PATTERN = f"“{{}}”是 {class_list} 里的什么类别？"
```

例如，针对句子：“张译（原名张毅），1978年2月17日出生于黑龙江省哈尔滨市，中国内地男演员。1997年至2006年服役于北京军区政治部战友话剧团。2006年，主演军事励志题材电视剧《士兵突击》。”

构造prompt后变为：

```
“张译（原名张毅），1978年2月17日出生于黑龙江省哈尔滨市，中国内地男演员。1997年至2006年服役于北京军区
['人物', '书籍', '电视剧'] 里的什么类别？
```

参考：https://github.com/HarderThenHarder/transformers_tasks/tree/main/LLM

那位科技

2）cls_pre_history实体类型识别的例子

利用cls_pre_history作为incontext-learning学习的上下文，进行拼接，例如，cls_pre_history形式为：

```
cls_pre_history:
[
    ("现在你是一个文本分类器，你需要按照要求将我给你的句子分类到：['人物', '书籍', '电视剧']类别中。'
    (
        "“岳云鹏，本名岳龙刚，1985年4月15日出生于河南省濮阳市南乐县，中国内地相声、影视男演员。2005年
》。2013年在北京举办相声专场。”是 ['人物', '书籍', '电视剧'] 里的什么类别？",
        '人物'
    ),
    (
        "“《三体》是刘慈欣创作的长篇科幻小说系列，由《三体》《三体2：黑暗森林》《三体3：死神永生》组成
月首次出版，第三部则于2010年11月出版。”是 ['人物', '书籍', '电视剧'] 里的什么类别？",
        '书籍'
    ),
    (
        "“《狂飙》是由中央电视台、爱奇艺出品，留白影视、中国长安出版传媒联合出品，中央政法委宣传教育局
张颂文、李一桐、张志坚、吴刚领衔主演，倪大红、韩童生、李建义、石兆琪特邀主演，李健、高叶、王骁等主演的反
        '电视剧'
    )
]
```

大模型用于知识图谱构建

思想：根据识别的实体类型结果做实体属性抽取，根据上一步得到的实体类型，进一步生成问句sentence_with_ie_prompt和in-context learning上下文。

1）sentence_with_ie_prompt

sentence_with_ie_prompt指的是对任务的描述，其中需要用到不同实体对应的属性schema以及问题的promt模版。

schema如下：

```
schema = {
    '人物': ['姓名', '性别', '出生日期', '出生地点', '职业', '获得奖项'],
    '书籍': ['书名', '作者', '类型', '发行时间', '定价'],
    '电视剧': ['电视剧名称', '导演', '演员', '题材', '出品方']
}
```

属性抽取的prompt如下：

```
IE_PATTERN = "{}\n\n提取上述句子中{}类型的实体，并按照JSON格式输出，上述句子中不存在的信息用['原
```

变成：

```
张译（原名张毅），1978年2月17日出生于黑龙江省哈尔滨市，中国内地男演员。1997年至2006年服役于北京军区

提取上述句子中“人物”(姓名，性别，出生日期，出生地点，职业，获得奖项)类型的实体，并按照JSON格式输出，
```

参考：https://github.com/HarderThenHarder/transformers_tasks/tree/main/LLM

那位科技

思想：根据识别的实体类型结果做实体属性抽取，根据上一步得到的实体类型，进一步生成问句sentence_with_ie_prompt和in-context learning上下文。

2）ie_pre_history属性抽取的例子

ie_pre_history属性抽取的例子给定了一些正确抽取的实际例子，如下所示：

```
[
    (
        "现在你需要帮助我完成信息抽取任务，当我给你一个句子时，你需要帮我抽取出句子中三元组，并按照J
个值之间用','分隔。",
        '好的，请输入您的句子。'
    ),
    (
        "岳云鹏，本名岳龙刚，1985年4月15日出生于河南省濮阳市南乐县，中国内地相声、影视男演员。\n\n
获得奖项)类型的实体，并按照JSON格式输出，上述句子中不存在的信息用['原文中未提及']来表示，多个值之间用
        '{"姓名": ["岳云鹏"], "性别": ["男"], "出生日期": ["1985年4月15日"], "出生地点": ["
["原文中未提及"]}'
    ),
    (
        "《三体》是刘慈欣创作的长篇科幻小说系列，由《三体》《三体2：黑暗森林》《三体3：死神永生》组成
，第三部则于2010年11月出版。\n\n提取上述句子中“书籍”(书名，作者，类型，发行时间，
定价)类型的实体，并按照JSON格式输出，上述句子中不存在的信息用['原文中未提及']来表示，多个值之间用','
        '{"书名": ["《三体》"], "作者": ["刘慈欣"], "类型": ["长篇科幻小说"], "发行时间": ["2
    )
]
```

大模型微调用于知识图谱构建策略

CCKS2023知识图谱构建任务

那位科技

- CCKS2023开放环境下的知识图谱构建与补全评测任务一：指令驱动的自适应知识图谱构建
- 地址：https://tianchi.aliyun.com/competition/entrance/532080/introduction

- 任务定义：

- *输入一段文本input和instruction（包括想要抽取的关系类型），以“(头实体,关系,尾实体)”的形式输出input中包含的所有关系三元组output。*

- *instruction="已知候选的关系列表：['父母','配偶']，请你根据关系列表，从以下输入中抽取出可能存在的头实体(Subject)与尾实体(Object)，并给出对应的关系三元组。请按照(Subject,Relation,Object)的格式回答。"*

- *input="2008年6月23日，刘德华与朱丽倩在美国拉斯维加斯注册结婚。2012年5月9日，朱丽倩在香港养和医院产下女儿刘向蕙。刘向蕙出生后，少数看过刘向蕙面貌的圈内人士称，女儿的耳朵像刘德华，长得眉清目秀。"*

- *output="(刘德华,配偶,朱丽倩),(刘向蕙,父母,刘德华),(刘向蕙,父母,朱丽倩)"*

CCKS2023知识图谱构建任务

- CCKS2023开放环境下的知识图谱构建与补全评测任务一：指令驱动的自适应知识图谱构建
- 在初赛训练集和验证集发布阶段，发布5000条左右的知识图谱数据作为训练集。这5000条数据是使用维基数据对中文维基百科进行远程监督标注的弱监督数据，所以可能会存在一些错误。

字段	说明
id	样本唯一标识符
cate	文本主题
input	模型输入文本（需要抽取其中涉及的所有关系三元组）
instruction	模型进行抽取任务的指令
output	模型期望输出，以(头实体,关系,尾实体)形式组成的输出文本
kg	text中涉及的知识图谱（由(头实体,关系,尾实体)三元组的格式组成）

文本主题为以下12种类型之一：

1.人物（人、虚拟的人、名称等）

2.地理地区（城市、国家、河流、山脉、大洲、湖泊等）

3.事件（战争、活动、赛事等）

4.组织（企业、政府机构、机构、家族、队伍等）

5.生物（动物、植物、微生物、种等）

6.人造物件（材料、食物、设备等）

7.化合物

8.医学（健康问题、生理状况等）

9.运输（物流、航空、铁路系统、船运等）

10.建筑（建筑物、设施等）

11.天文对象（天体等）

12.作品（电影、数据、音乐等）

CCKS2023知识图谱构建任务

- CCKS2023开放环境下的知识图谱构建与补全评测任务一：指令驱动的自适应知识图谱构建
- 地址：https://tianchi.aliyun.com/competition/entrance/532080/introduction

- 任务定义：

- *nstruction="已知候选的关系列表：['父母','配偶']，请你根据关系列表，从以下输入中抽取出可能存在的头实体(Subject)与尾实体(Object)，并给出对应的关系三元组。请按照(Subject,Relation,Object)的格式回答。"*

- *miss_input="2012年5月9日，朱丽倩在香港养和医院产下女儿刘向蕙。刘向蕙出生后，少数看过刘向蕙面貌的圈内人士称，女儿的耳朵像刘德华，长得眉清目秀。"*

- *output="(刘德华,配偶,朱丽倩),(刘向蕙,父母,刘德华),(刘向蕙,父母,朱丽倩)"*

- *虽然miss_input中不包含"2008年6月23日，刘德华与朱丽倩在美国拉斯维加斯注册结婚。"这段文字，但是模型能够补齐缺失的三元组，(刘德华,配偶,朱丽倩),(刘向蕙,父母,刘德华)。*

大模型微调用于知识图谱

- CCKS2023开放环境下的知识图谱构建与补全评测任务一：指令驱动的自适应知识图谱构建
- 代码实现：https://github.com/zjunlp/DeepKE/blob/main/example/triple/mt5/README_ZH.md

你可以通过下面的脚本开始finetune模型:

```
bash run_finetene_ds.bash
```

或者通过下面的命令设置自己的参数执行:

```
deepspeed  --include localhost:0,1 run_finetune.py \
    --do_train --do_eval --do_predict \
    --num_train_epochs 10 \
    --per_device_train_batch_size 16 \
    --per_device_eval_batch_size 48 \
    --gradient_accumulation_steps 2 \
    --predict_with_generate \
    --from_checkpoint=True \
    --overwrite_output_dir=False \
    --model_name_or_path google/mt5-base   \
    --output_dir output/ccks_mt5-base_f1_1e-4  \
    --logging_dir output/ccks_mt5-base_f1_1e-4_log \
    --train_file data/train.json \
    --test_file data/valid.json \
    --save_total_limit 1 \
    --load_best_model_at_end \
    --save_strategy "epoch" \
    --evaluation_strategy "epoch" \
    --metric_for_best_model "overall-score" \
    --learning_rate 1e-4 \
    --use_fast_tokenizer=True \
    --preprocessing_num_workers 4 \
    --generation_max_length 256 \
    --generation_num_beams 1 \
    --gradient_checkpointing=True \
    --deepspeed "configs/ds_mt5_z3_config_bf16.json" \
    --seed 42 \
    --bf16=True \
```

你可以通过以下命令对训练后的模型进行推理和预测, model_name是训练好的模型的路径, output_dir是输出路径

```
model_name="output/ccks_mt5-base_f1_1e-4"
output_dir="output/ccks_mt5-base_f1_1e-4_test_result"
data_dir="data"

deepspeed  --include localhost:0 run_finetune.py \
    --do_predict \
    --predict_with_generate \
    --use_fast_tokenizer=True \
    --per_device_eval_batch_size 16 \
    --test_file=${data_dir}/valid.json \
    --model_name_or_path=${model_name}   \
    --output_dir=${output_dir}  \
    --overwrite_output_dir=False \
    --logging_dir=${output_dir}_log \
    --preprocessing_num_workers 4 \
    --generation_max_length 256 \
    --generation_num_beams 1 \
    --gradient_checkpointing=True \
    --bf16=True \
    --deepspeed "configs/ds_mt5_z3_config_bf16.json" \
    --seed 42
```

大模型微调用于知识图谱

那位科技

- CCKS2023开放环境下的知识图谱构建与补全评测任务一：指令驱动的自适应知识图谱构建
- 代码实现：https://github.com/zjunlp/DeepKE/blob/main/example/llm/README_CN.md

- 环境依赖
- 数据
- 模型
  - LLaMA系列
    - 案例一：LoRA微调LLaMA完成CCKS2023指令驱动的知识图谱构建 英文 | 中文
    - 案例二：使用智析完成CCKS2023指令驱动的知识图谱构建 英文 | 中文
  - ChatGLM
    - 案例一：LoRA微调ChatGLM完成CCKS2023指令驱动的知识图谱构建 英文 | 中文
    - 案例二：P-Tuning微调ChatGLM完成CCKS2023指令驱动的知识图谱构建 英文 | 中文
  - MOSS
    - 案例一：Lora微调Moss完成CCKS2023指令驱动的知识图谱构建 英文 | 中文
  - Baichuan
    - Case 1: Lora微调Baichuan完成CCKS2023指令驱动的知识图谱构建 英文 | 中文
  - CPM-Bee
    - 案例一：OpenDelta微调CPM-Bee完成CCKS2023指令驱动的知识图谱构建 英文 | 中文
  - GPT系列
    - 案例一：ICL使用大语言模型进行信息抽取 英文 | 中文
    - 案例二：ICL使用大语言模型进行数据增强 英文 | 中文
    - 案例三：ICL使用大语言模型完成CCKS2023指令驱动的知识图谱构建 英文 | 中文
    - 案例四：ICL释放大型语言模型进行少样本关系抽取中的能力 英文 | 中文
    - 案例五：CodeKGC-基于代码语言模型的知识图谱构建 英文 | 中文
- 方法
  - 方法一：In-Context Learning(ICL)
  - 方法二：LoRA
  - 方法三：P-Tuning
- 引用

大模型微调用于知识图谱

那位科技

- 开源的信息抽取数据
- 地址：https://github.com/zjunlp/DeepKE/blob/main/example/llm/README_CN.md

名称	下载	数量	描述
InstructIE-train	Google drive HuggingFace 百度云盘	30w+	InstructIE训练集，基于弱监督构建得到，包含一定程度的噪音数据
InstructIE-valid	Google drive HuggingFace 百度云盘	2000+	InstructIE验证集
InstructIE-test	Google drive HuggingFace 百度云盘	2000+	InstructIE测试集
train.json, valid.json	Google drive	5000	CCKS2023 开放环境下的知识图谱构建与补全评测任务一：指令驱动的自适应知识图谱构建 中的初赛训练集及测试集

大模型微调用于知识图谱

那位科技

- 指令数据的转换
  - 转换前：数据的格式需要符合 DeepKE/example/llm/InstructKGC/data 目录下为各项任务(如NER、RE、EE等)规定的结构。以NER任务为例，输入文本应标记为input字段，而标注数据则应标记为entity字段，它是一个包含多个entity和entity_type键值对的字典列表。
  - 转换后：将得到包含input文本、instruction指令（详细说明了候选标签列表['组织机构'，'人物'，'地理位置']和期望的输出格式(实体,实体类型)），以及output（以(实体,实体类型)形式列出在input中识别到的所有实体信息）的结构化数据。
  - 地址：https://github.com/zjunlp/DeepKE/blob/main/example/llm/InstructKGC/README_CN.md/#48lora微调baichuan

转换前：

```
{
    "input": "相比之下，青岛海牛队和广州松日队的雨中之战虽然也是0:0，但乏善可陈。",
    "entity": [{"entity": "广州松日队", "entity_type": "组织机构"}, {"entity": "青岛海牛队", "entity_type": "组织机构"}]
}
```

转换后：

```
{
    "id": "e88d2b42f8ca14af1b77474fcb18671ed3cacc0c75cf91f63375e966574bd187",
    "instruction": "请在所给文本中找出并列举['组织机构', '人物', '地理位置']提及的实体类型，不存在的类型请注明为NAN。回答应按(实体,
    "input": "相比之下，青岛海牛队和广州松日队的雨中之战虽然也是0:0，但乏善可陈。",
    "output": "(青岛海牛队,组织机构)\n(广州松日队,组织机构)\nNAN\nNAN"
}
```

大模型微调用于知识图谱

- 信息抽取模板：模版template用于构造输入模型的指令instruction，由三部分组成：
  - 任务描述：明确模型的职能及其需完成的任务，例如实体识别、关系抽取、事件抽取等。
  - 候选标签列表{s_schema}(可选)：定义模型需要提取的标签类别，如实体类型、关系类型、事件类型等。
  - 结构化输出格式{s_format}：指明模型应如何呈现其抽取的结构化信息。

指定候选标签列表的模版:

```
实体命名识别(NER): 你是专门进行实体抽取的专家。已知候选的实体类型列表: {s_schema}，请你根据实体类型列表，从以下输入中抽取出可能存在的实
关系抽取(RE): 你在这里扮演关系三元组识别师的角色。我将给你个输入，请根据关系列表: {s_schema}，从输入中抽取出可能包含的关系三元组，，如
事件抽取(EE): 你是专门进行事件提取的专家。已知候选的事件字典: {s_schema}，请你根据事件字典，从以下输入中抽取出可能存在的事件，如果不存
事件类型抽取(EET): 作为事件分析专员，你需要查看输入并根据事件类型名录: {s_schema}，来确定可能发生的事件。所有回答都应该基于{s_format
事件论元抽取(EEA): 你是专门进行事件论元提取的专家。已知事件字典: {s_schema1}，事件类型及触发词: {s_schema2}，请你从以下输入中抽取出
```

▼ **不指定候选标签列表的模版**

```
实体命名识别(NER): 分析文本内容，并提取明显的实体。将您的发现以{s_format}格式提出，跳过任何不明显或不确定的部分。
关系抽取(RE): 请从文本中抽取出所有关系三元组，并根据{s_format}的格式呈现结果。忽略那些不符合标准关系模板的实体。
事件抽取(EE): 请分析下文，从中抽取所有可识别的事件，并按照指定的格式{s_format}呈现。如果某些信息不构成事件，请简单跳过。
事件类型抽取(EET): 审视下列文本内容，并抽取出任何你认为显著的事件。将你的发现整理成{s_format}格式提供。
事件论元抽取(EEA): 请您根据事件类型及触发词{s_schema2}从以下输入中抽取可能的论元。请按照{s_format}的格式回答。
```

▼ **候选标签列表{s_schema}**

```
NER(CLUE): ["书名", "地址", "电影", "公司", "姓名", "组织机构", "职位", "游戏", "景点", "政府"]
RE(DuIE): ["创始人", "号", "注册资本", "出版社", "出品公司", "作词", "出生地", "连载网站", "祖籍", "制片人", "出生日期", "主演
EE(DuEE-fin): {"质押": ["披露时间", "质押物占总股比", "质押物所属公司", "质押股票/股份数量", "质押物", "质押方", "质押物占持股比
EET(DuEE): ["交往-感谢", "组织行为-开幕", "竞赛行为-退赛", "组织关系-加盟", "组织关系-辞/离职", "财经/交易-涨价", "人生-产子/女
EEA(DuEE-fin): {"质押": ["披露时间", "质押物占总股比", "质押物所属公司", "质押股票/股份数量", "质押物", "质押方", "质押物占持股
```

大模型微调用于知识图谱

那位科技

- 信息抽取模板： 多样化的prompt
  - ner： https://github.com/zjunlp/DeepKE/blob/main/example/llm/InstructKGC/configs/ner_template.json
  - re:https://github.com/zjunlp/DeepKE/blob/main/example/llm/InstructKGC/configs/re_template.json
  - eet:https://github.com/zjunlp/DeepKE/blob/main/example/llm/InstructKGC/configs/eet_template.json
  - eea:https://github.com/zjunlp/DeepKE/blob/main/example/llm/InstructKGC/configs/eea_template.json
  - ee:https://github.com/zjunlp/DeepKE/blob/main/example/llm/InstructKGC/configs/ee_template.json


```
"zh": {
    "template": {
        "0": "你是专门进行实体抽取的专家。已知候选的实体类型列表：{s_schema}，请你根据实体类型列表，从以下输入中抽取出可能存在的实体，如果不存在某实体就输出NAN。请按照{s_format}的格式回答。",
        "1": "你扮演的角色是实体抽取师。我将给你个输入，请根据实体类型列表：{s_schema}，从输入中抽取出可能包含的实体，如果不存在某实体就输出NAN，并以{s_format}的形式回答。",
        "2": "你在这里作为一个实体识别员。我希望你根据实体类型列表从给定的输入中抽取可能的实体，如果不存在某实体就输出NAN，并以{s_format}的格式回答。实体类型列表={s_schema}。",
        "3": "你是负责实体提取的专员。给定的实体类型列表是{s_schema}\n根据实体类型列表，在这个句子中可能包含哪些实体？你可以先列出实体，再判断实体类型，如果不存在某实体就输出NAN。请以{s_format}的格式
        "4": "请将您的专业知识应用于实体抽取。在审查以下文本后，依据{s_schema}提供的实体类型清单识别并列出实体。如遇到列表中未提及的类型，请标记为NAN，并确保使用{s_format}格式进行答复。",
        "5": "以您对实体抽取的深入理解，研究接下来的文本。参照{s_schema}中定义的实体类型，挑选并标明文本中的实体。若某实体类型在文本中未出现，请使用NAN代替，并遵循{s_format}格式答复。",
        "6": "考虑到您在实体识别方面的专长，请浏览下列内容，并根据{s_schema}所列出的实体类型来标注相应实体。不存在的实体类型应用NAN表示，并请严格按照{s_format}的要求格式化您的回答。",
        "7": "利用您的专业技能，在以下文本中识别出各种实体类型。请根据{s_schema}中提供的分类进行，并对于不出现的类型使用NAN标识。您的回答应该遵循{s_format}格式指引。",
        "8": "请运用您的实体分析技巧，对下文进行解读，并根据{s_schema}中列举的实体类型进行分类标注。如果发现某一类型不存在，请用NAN填充，并按{s_format}的结构提供您的答案。",
        "9": "作为实体分析的专家，您需要从所给的文本中找出{s_schema}定义的实体类型。对于那些未在文本中找到的类型，请标记为NAN，并按照{s_format}提供格式化的回答。",
        "10": "请展示您在实体抽取方面的专业技术。检查以下段落，并按照{s_schema}概述的实体类型进行识别。若无相应实体，请注明为NAN，并依照{s_format}格式回答。",
        "11": "把您对实体分类的理解应用于以下文本。依据实体类型列表{s_schema}来定位并标记实体，如果文本中缺少某个类型的实体，请以NAN表示，并确保您的答案符合{s_format}格式。",
        "12": "请精确地从下述文本中提取实体，并参考{s_schema}中的实体类型列表进行分类。如某类实体不出现，用NAN替代，并按照格式{s_format}答复。",
        "13": "您的任务是从提供的文本中识别出所有相关的实体类别。依据提供的{s_schema}列表进行工作，遇到不存在的实体类别请标示为NAN，并使用{s_format}作为您回答的格式。",
        "14": "请检查文本，并根据实体类型清单{s_schema}识别出现的实体。对于清单中未提及的实体类型，请标记为NAN，并遵循{s_format}格式回答。",
        "15": "分析以下内容，提取对应于{s_schema}的实体类型。若所需实体类型缺失，请用\"NAN\"表示，并确保答案格式符合{s_format}。",
        "16": "浏览下述文本，依据{s_schema}中的分类识别实体。对于未检测到的实体类型，请使用\"NAN\"填充，并按照{s_format}格式化您的回答。",
        "17": "请在所给文本中找出并列举{s_schema}提及的实体类型，不存在的类型请注明为NAN。回答应按{s_format}格式进行。",
        "18": "研究文本，根据{s_schema}抽取实体。对于列表中未出现的实体类型，回答时请标识为NAN，并且遵循{s_format}的回答格式。",
        "19": "审视文本并根据{s_schema}指定的实体类型来提取信息。在回答中，未发现的类型应标注为NAN，并按照{s_format}的规范排列。"
    }
```

大模型微调用于知识图谱

那位科技

- 信息抽取模板：模版template用于构造输入模型的指令instruction，由三部分组成：
  - 任务描述：明确模型的职能及其需完成的任务，例如实体识别、关系抽取、事件抽取等。
  - 候选标签列表{s_schema}(可选)：定义模型需要提取的标签类别，如实体类型、关系类型、事件类型等。
  - 结构化输出格式{s_format}：指明模型应如何呈现其抽取的结构化信息。

▼ **结构输出格式{s_format}**

```
实体命名识别(NER)：(实体,实体类型)

关系抽取(RE)：(头实体,关系,尾实体)

事件抽取(EE)：(事件触发词,事件类型,事件论元1#论元角色1;事件论元2#论元角色2)

事件类型抽取(EET)：(事件触发词,事件类型)

事件论元抽取(EEA)：(Event Trigger,Event Type,Argument1#Argument Role1;Argument2#Argument Role2)
```

那位科技&慕课

那位科技

➢指令数据的转换

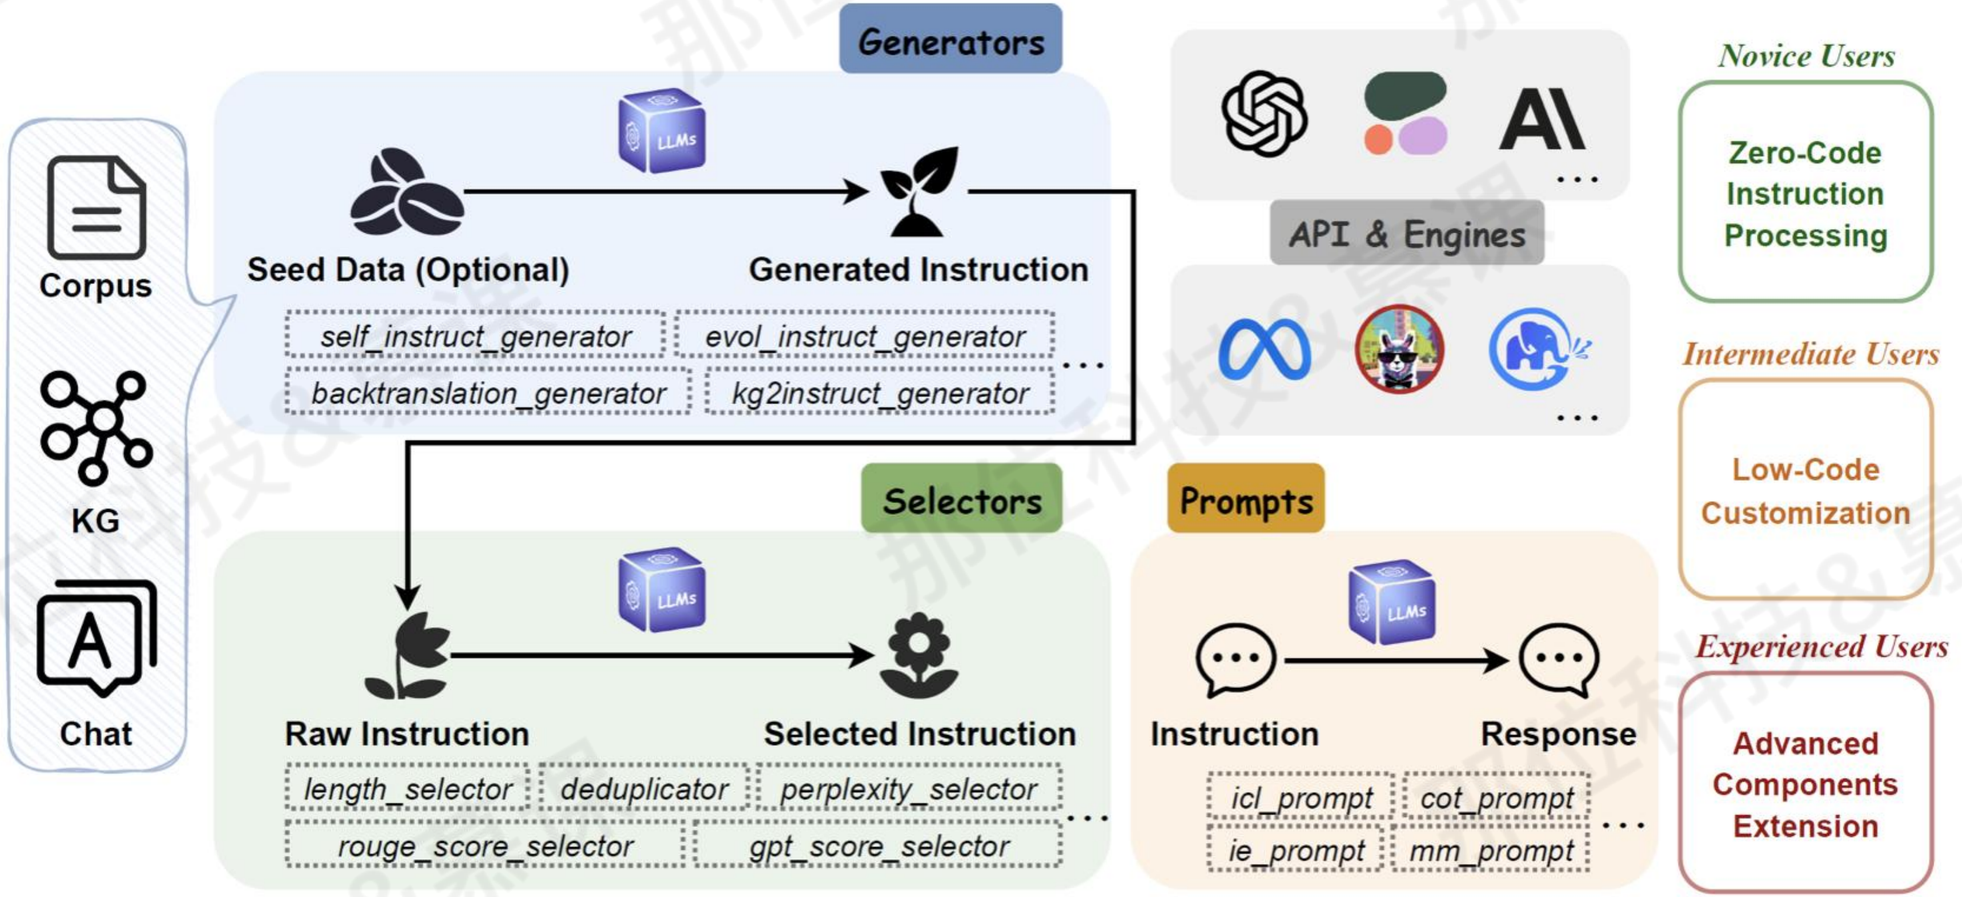
- 转换前

```
关系抽取(RE): {
    "input": "如何演好自己的角色，请读《演员自我修养》《喜剧之王》周星驰崛起于穷困潦倒之中的独门秘笈",
    "relation": [{"head": "喜剧之王", "relation": "主演", "tail": "周星驰"}]
}
事件抽取(EE): {
    "input": "消失的“外企光环”，5月份在华裁员900余人，香饽饽变“臭”了",
    "event": [{"event_trigger": "裁员", "event_type": "组织关系-裁员", "arguments": [{"argument": "900余人", "role":
}
事件类型抽取(EET): {
    "input": "前两天，被称为 “ 仅次于苹果的软件服务商 ” 的 Oracle （ 甲骨文 ）公司突然宣布在中国裁员。。",
    "event": [{"event_trigger": "裁员", "event_type": "组织关系-裁员", "arguments": [{"argument": "前两天", "role": "
}
事件论元抽取(EEA): {
    "input": "不仅仅是中国IT企业在裁员，为何500强的甲骨文也发生了全球裁员",
    "event": [{"event_trigger": "裁员", "event_type": "组织关系-裁员", "arguments": [{"argument": "中国IT企业", "role'
}
```

```
:a48bd84385743ed453ea57dbe743c7c",
                                                
```

大模型用于图谱数据增强

- 为了弥补少样本场景下关系抽取有标签数据的缺失，设计带有数据样式描述的提示，用于指导大型语言模型根据已有的少样本数据自动地生成更多的有标签数据。
- 地址：https://github.com/zjunlp/EasyInstruct/tree/main



大模型用于图谱数据增强

- 核心思想：使用fewshot，对大模型进行蒸馏
- 地址：https://github.com/zjunlp/EasyInstruct/tree/main

```
'''
One sample in relation extraction datasets consists of a relation, a context, a pair of head and tail
entities in the context and their entity types.

The head entity has the relation with the tail entity and entities are pre-categorized as the following
types: URL, LOCATION, IDEOLOGY, CRIMINAL CHARGE, TITLE, STATE OR PROVINCE, DATE, PERSON, NUMBER, CITY,
DURATION, CAUSE OF DEATH, COUNTRY, NATIONALITY, RELIGION, ORGANIZATION, MISCELLANEOUS.

Here are some samples for relation 'org:founded_by':

Relation: org:founded_by. Context: Talansky is also the US contact for the New Jerusalem Foundation ,
an organization founded by Olmert while he was Jerusalem 's mayor . Head Entity: New Jerusalem
Foundation. Head Type: ORGANIZATION. Tail Entity: Olmert. Tail Type: PERSON.

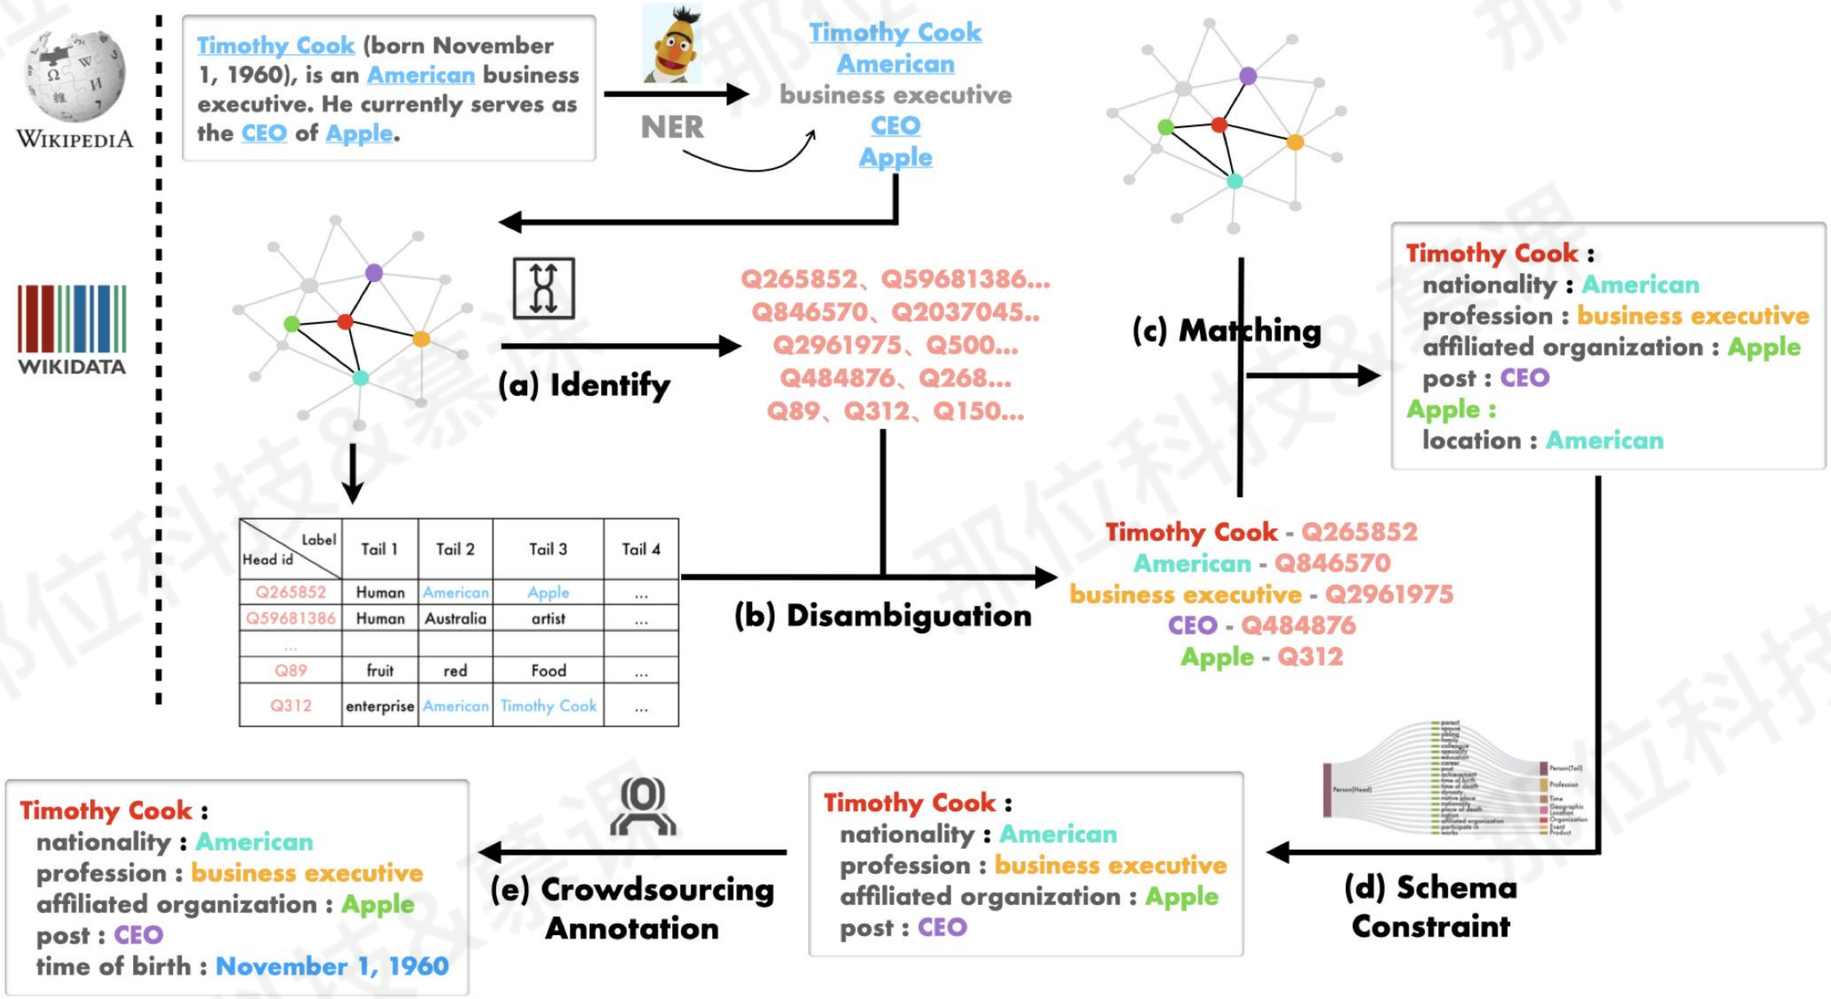
Relation: org:founded_by. Context: Sharpton has said he will not endorse any candidate until hearing
more about their views on civil rights and other issues at his National Action Network convention next
week in New York City . Head Entity: National Action Network. Head Type: ORGANIZATION. Tail Entity:
his. Tail Type: PERSON.

Relation: org:founded_by. Context: `` We believe that we can best serve our clients by offering a
single multistrategy hedge fund platform , '' wrote John Havens , who was a founder of Old Lane with
Pandit and is president of the alternative investment group . Head Entity: Old Lane. Head Type:
ORGANIZATION. Tail Entity: John Havens. Tail Type: PERSON.

Generate more samples for the relation 'org:founded_by'.
'''
```

大模型用于图谱数据增强

- KG2instruct：基于大模型针对维基百科生成数据
- 地址：https://arxiv.org/pdf/2305.11527.pdf



大模型用于图谱数据增强

- KG2instruct：基于大模型针对维基百科生成数据
- 地址：https://github.com/zjunlp/EasyInstruct/blob/main/easyinstruct/generators/kg2instruct_generator.py

```
def generate(self, input):
    text_list = [
        input,
    ]
    # 1、ner识别实体，返回 List[List[List[str]]]
    hanlp_entities_list = ner(text_list, self.HanLP, self.language, self.chunk)

    # 2、从alias_rev_db中找到对应的wikidata ID，返回List[List[List[str]]]
    new_entities_list = []
    for entities in hanlp_entities_list:
        new_entities = []
        for entity in entities:
            try:
                iids = self.alias_rev_db[format_wikilink(entity[0])]
            except KeyError:
                continue
            if len(iids) > 0:
                iids = iids[0]
                new_entities.append([entity[0], iids])
        new_entities_list.append(new_entities)

    # 3、对实体进行消歧，每个实体都得到唯一的wikidata ID，返回List[List[List[str]]]
    match_entities_list = match_qid(
        new_entities_list,
        self.label_db,
        self.alias_db,
        self.alias_rev_db,
        self.relation_db,
        self.language,
    )
```

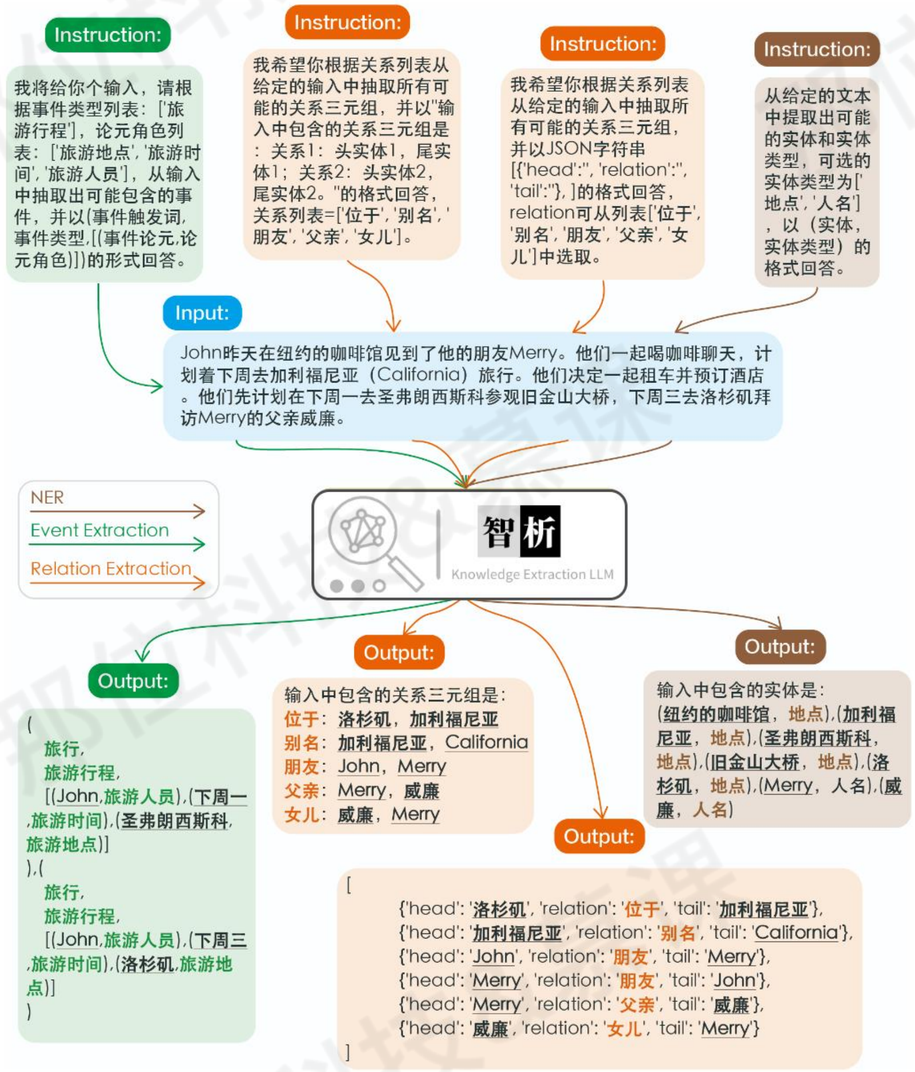
```
# 4、匹配实体间的关系，返回{'text':List[str], 'entity':List[List[List[str]]], 'relation': List[List[Dict]]}
annotator = Annotator(
    self.alias_db,
    self.relation_db,
    self.relation_value_db,
    self.relation_map_path,
    self.language,
)

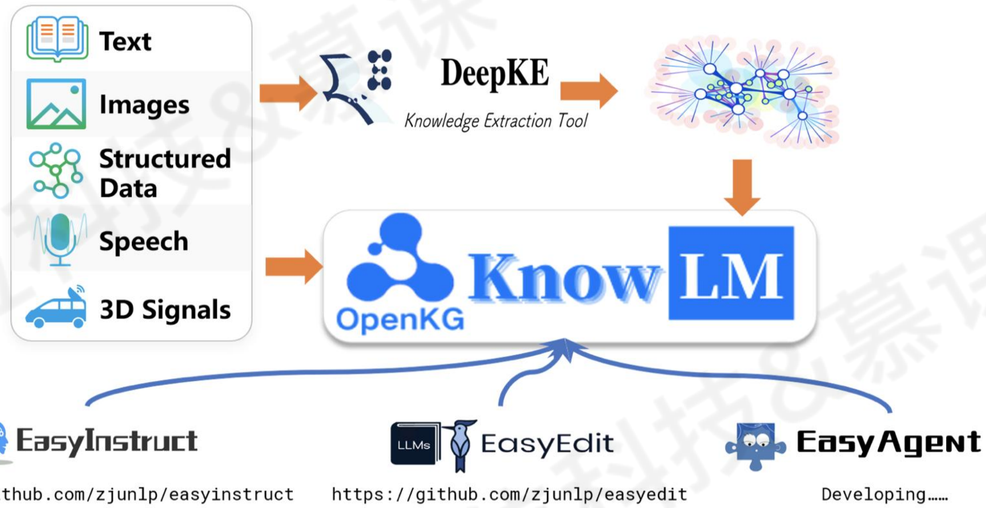
for text, entities in zip(text_list, match_entities_list):
    if len(entities) == 0:
        continue
    relations, new_entities = annotator.annotate(entities, text)
return {"text": text, "entity": new_entities, "relation": relations}
```

面向知识图谱构建的微调大模型回顾

知识图谱微调大模型

- https://github.com/zjunlp/KnowLM#2-2
- 基于知识图谱转换指令技术对知识抽取任务，包括NER、RE、IE进行优化，可以使用人类指令来完成信息抽取任务





知识图谱微调大模型

- https://github.com/neukg/TechGPT
- http://techgpt.neukg.com
- TechGPT主要强化了如下三类任务：
  - 以“知识图谱构建”为核心的关系三元组抽取等各类信息抽取任务
  - 以“阅读理解”为核心的智能问答任务。
  - 以“文本理解”为核心的关键词生成的序列生成任务



那位科技

thanks 👋